浙江大学实验报告

专业：电子科学与技术
姓名：郑智瑄
学号：3230103913
日期：March 13, 2026
地点：东 4-216

课程名称：人工智能实验　　指导老师：魏准　　实验类型：设计型实验
实验名称：实验 1-2,1-3,2-1　　成　绩：　　签　名：

装 订 线

一、 实验 1-2：约会网站数据分析与可视化

1. 实验目的

利用 Matplotlib 对约会网站样本数据进行多维度可视化分析，观察不同特征（飞行里程、游戏时间、冰淇淋消费）对用户类别标签的影响。

2. 实验原理

分类问题是通过已知的特征预测特定的实例类别。在该数据集中，标签分为三个等级：不喜欢的人（1）、魅力一般的人（2）和极具魅力的人（3）。通过散点图（Scatter Plot）可以将三维特征两两组合，在二维平面上观察类别的分布规律。

3. 核心代码实现

```python
datingDataMat, datingLabels = kNN.file2matrix('datingTestSet2.txt')
colors = {1: 'red', 2: 'green', 3: 'blue'}
c = [colors[l] for l in datingLabels]
legend_labels = [mpatches.Patch(color='red',   label='不喜欢'),
                 mpatches.Patch(color='green', label='一般'),
                 mpatches.Patch(color='blue',  label='很喜欢')]

def draw_scatter(x, y, xlabel, ylabel, title):
    fig, ax = plt.subplots(figsize=(6, 5))
    ax.scatter(x, y, c=c, s=10)
    ax.set_xlabel(xlabel); ax.set_ylabel(ylabel); ax.set_title(title)
    ax.legend(handles=legend_labels)
    fig.tight_layout()

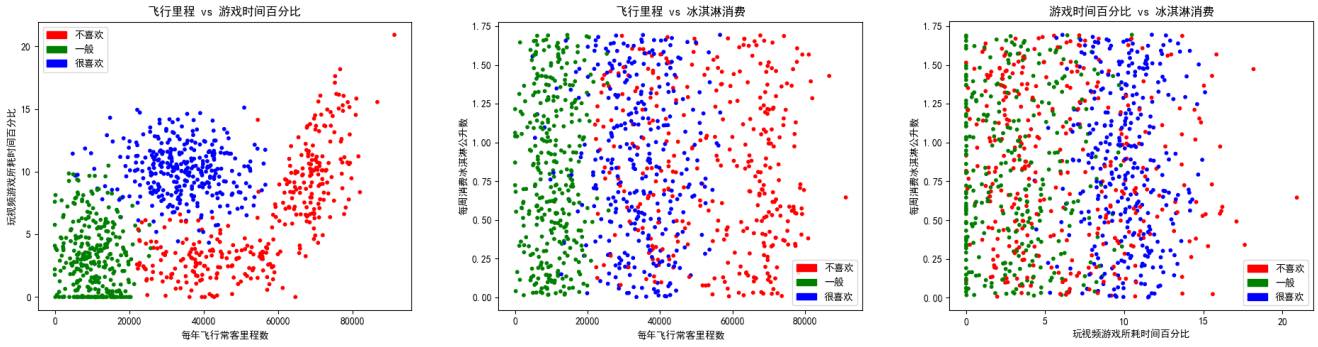
# 分别绘制三组特征组合的散点图
draw_scatter(datingDataMat[:,0], datingDataMat[:,1],
             '每年飞行常客里程数', '玩视频游戏所耗时间百分比',
             '飞行里程 vs 游戏时间百分比')
# ... 其余两组类似，分别对 [:,0] vs [:,2] 和 [:,1] vs [:,2]
plt.show()
```

Listing 1: 数据可视化完整代码 (Data_display.py)

4. 实验结果分析

通过绘制的三组散点图，可以清晰地看到：

- **飞行里程与游戏时间**（图 1a）：数据呈现明显的簇状分布，不同类别的重叠度较低，这两个特征对分类有较强的区分度。
- **冰淇淋消费**（图 1b、图 1c）：与其他特征结合时，数据点分布较为弥散，说明该特征对分类结果的影响相对较小。



(a) 飞行里程 vs 游戏时间　　(b) 飞行里程 vs 冰淇淋消费　　(c) 游戏时间 vs 冰淇淋消费

Figure 1: 三组特征组合的散点图对比

二、 实验 1-3：k-近邻算法测试与准确率评估

1. 实验目的

编写程序测试 kNN 分类器在约会数据集上的性能，并计算错误率与准确率。

2. 实验原理

(1) **数据归一化**：为防止数值较大的特征（如飞行里程）对距离计算产生压倒性影响，需进行归一化处理：

$$newValue = \frac{oldValue - min}{max - min}$$

(2) **算法流程**：计算新数据与训练集各点的欧氏距离，选取距离最近的 k 个点（本实验 $k = 3$），通过投票决定最终类别。

3. 核心代码实现

```python
import kNN

def datingClassTest():
    datingDataMat, datingLabels = kNN.file2matrix('datingTestSet2.txt')
    normMat, ranges, minVals = kNN.autoNorm(datingDataMat)
    m = normMat.shape[0]
    numTestVecs = int(m * 0.10)
    errorCount = 0.0
    for i in range(numTestVecs):
        result = kNN.classify0(normMat[i, :], normMat[numTestVecs:m, :],
                               datingLabels[numTestVecs:m], 3)
        if result != datingLabels[i]:
            errorCount += 1.0
    print(f"错误率: {errorCount / float(numTestVecs):.2%}")
    print(f"准确率: {1 - errorCount / float(numTestVecs):.2%}")
```

Listing 2: 算法测试逻辑 (exp1_3_dating_test.py)

4. 运行结果

程序运行的终端输出（节选）如下：

```
预测: 3, 实际: 3
预测: 2, 实际: 2
预测: 1, 实际: 1
...
预测: 3, 实际: 2 [X]
...
预测: 3, 实际: 1 [X]
...
预测: 3, 实际: 1 [X]
...
预测: 2, 实际: 3 [X]
...
预测: 3, 实际: 1 [X]
...

错误率: 5.00%
准确率: 95.00%
```

5. 结果分析

在 $k = 3$、测试比例为 10% 的条件下，共 100 个测试样本中有 5 个被错误分类，错误率为 5.00%，准确率为 95.00%。错误样本主要集中在类别 2（魅力一般）与类别 1、3 的边界区域，说明这些区域的特征分布存在一定重叠。整体而言，kNN 分类器表现良好，达到了预期要求。

装 订 线

三、 实验 2-1：线性回归的标准方程解法

1. 实验目的

通过标准方程法（Standard Equation）求解线性回归模型的参数 θ，实现对随机生成含噪数据的拟合与预测。

2. 实验原理

线性回归预测模型定义为对特征的加权求和：

$$\hat{y} = \theta \cdot x = \theta_0 x_0 + \theta_1 x_1 + \cdots + \theta_n x_n$$

其中 $x_0 = 1$。使用标准方程求解使成本函数最小化的 $\hat{\theta}$ 值：

$$\hat{\theta} = (X^T X)^{-1} X^T y$$

3. 核心代码实现

```python
import numpy as np
import matplotlib.pyplot as plt

# 生成随机数据：100 个 x [0,2], y = 4 + 3x + 噪声
X = 2 * np.random.rand(100, 1)
y = 4 + 3 * X + np.random.randn(100, 1)

# 标准方程求解：  = (X^T X)^{-1} X^T y
X_b = np.c_[np.ones((100, 1)), X]
theta = np.linalg.inv(X_b.T @ X_b) @ X_b.T @ y

# 预测 x=0, x=2
X_new = np.array([[0], [2]])
X_new_b = np.c_[np.ones((2, 1)), X_new]
y_pred = X_new_b @ theta

# 可视化
plt.plot(X, y, "b.", label="Data")
plt.plot(X_new, y_pred, "r-", label="Prediction")
plt.axis([0, 2, 0, 15])
plt.xlabel("$x_1$"); plt.ylabel("$y$")
plt.legend(); plt.title("Linear Regression - Exp 2-1")
plt.show()
```

Listing 3: 标准方程求解与预测 (exp2_1_linear_regression.py)

4. 运行结果

程序运行的终端输出如下：

```
theta = [4.01715538 2.9316735 ]
x=0 -> y=4.0172, x=2 -> y=9.8805
```

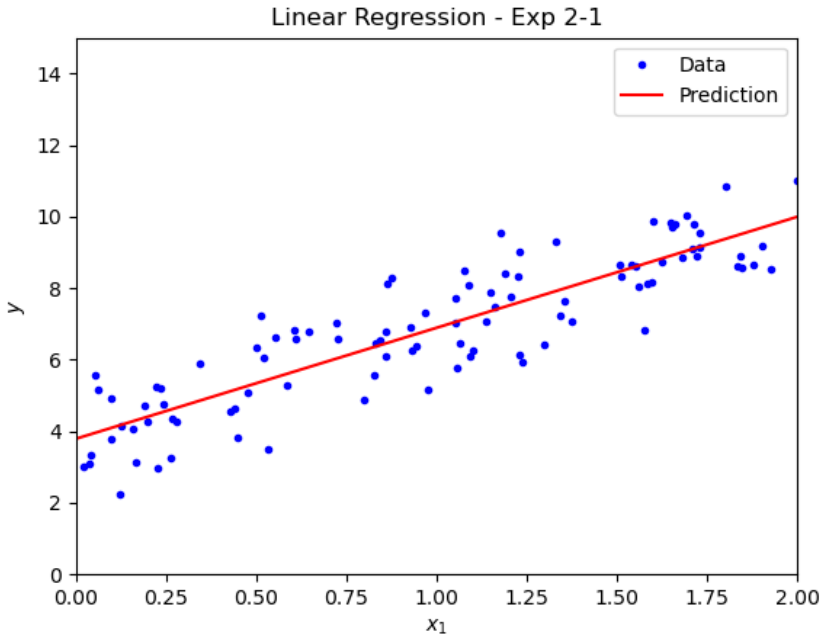


Figure 2: 线性回归拟合结果可视化

装 订 线

5. 结果分析

如图 2 所示，红色直线有效地穿过了带噪声的蓝色样本点群。程序求得 $\theta_0 \approx 4.017$，$\theta_1 \approx 2.932$，与数据生成方程 $y = 4 + 3x$ 高度吻合。对 $x = 0$ 预测 $y = 4.0172$（理论值 4），对 $x = 2$ 预测 $y = 9.8805$（理论值 10），误差极小，验证了标准方程解法的正确性。