

Topic 2 分类与回归

Part 1：分类模型

魏准
浙江大学，信息与电子工程学院

总体内容

分类：Classification is a predictive modeling problem where the class label is anticipated for a specific example of input data;

算法：k-近邻算法（k-Nearest Neighbor，KNN）进行分类

主要知识点

- k-近邻算法概述；
- k-近邻算法一般步骤；
- k-近邻算法代码实现；
  - ◆ AB分类；
  - ◆ 约会网站的配对效果分类；

1.1：k-近邻算法概述

k-近邻算法：采用测量不同**特征**值之间的**距离**方法进行分类。

工作原理：

- 存在一个**样本数据集合**，也称作训练样本集，并且样本集中每个数据都存在**标签**，即我们知道样本集中每一数据与所属分类的对应关系。
- 输入**没有标签的新数据**后，将新数据的每个**特征**与样本集中数据对应的**特征**进行比较，然后算法提取**样本集**中特征**最相似数据（最近邻）**的分类标签。
- 一般来说，我们只选择样本数据集中**前k个最相似**的数据，这就是k-近邻算法中k的出处，通常k是不大于20的整数。最后，选择k个最相似数据中**出现次数最多**的分类，作为新数据的分类。

1.2：一般步骤

- 定义样本数据集合函数（训练样本集），输出样本数据集特征及其标签。
- 定义k-近邻算法函数，输入为需要测试的数据特征，样本数据集特征及其标签、k值。通过计算比较测试的数据与样本数据特征的距离，找到k个最相邻的数据及其标签，k个数据中标签次数最多的标签作为输出测试数据的分类结果。
- 测试上述函数。

1.3：kNN代码实现-AB分类

Step1 样本数据产生函数：创建名为**kNN.py**的Python模块

```
from numpy import *
import operator
from os import listdir
def createDataSet():
    group = array([[1.0,1.1],[1.0,1.0],[0,0],[0,0.1]])
    labels = ['A','A','B','B']
    return group, labels
```


浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

Step2 k-近邻算法函数

- 输入参数-用于分类的输入向量是inX，输入的训练样本集为dataSet，标签向量为labels，最后的参数k表示用于选择最近邻居的数目。
- 计算向量a、b之间的距离：d=$\sqrt{(a1-b1)^2+(a1-b1)^2}$，并做排序。

```
def classify0(inX, dataSet, labels, k):
    dataSetSize = dataSet.shape[0]
    diffMat = tile(inX, (dataSetSize,1)) - dataSet
    sqDiffMat = diffMat**2
    sqDistances = sqDiffMat.sum(axis=1)
    distances = sqDistances**0.5
    sortedDistIndicies = distances.argsort()
```

argsort：返回排序后的索引值：由小到大

- 确定前k个距离最小元素所在的主要分类：(1)*votellabel*值为*A或者B*；（2）计算值为A/B的个数，并更新于字典classCount的*votellabel*索引下。
- sorted 函数：排序函数, reverse=ture表示降序，返回list（索引[0][0]为第一个元素）。
- items函数: 以列表返回可遍历的(键, 值) 元组数组。
- operator.itemgetter(1)：按照第二个元素值排序。

```
classCount={}
    for i in range(k):
        voteIlabel = labels[sortedDistIndicies[i]]
        classCount[voteIlabel] = classCount.get(voteIlabel,0) + 1
    sortedClassCount = sorted(classCount.items(),
key=operator.itemgetter(1), reverse=True)
    return sortedClassCount[0][0]
```

Step3 测试产生的函数

实验1-1：编写程序，创建名为tests.py的Python模块，利用classify0函数，分别取k=1、2、3；测试[0,0]、[0.8,0.7] 点的类别

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

1.4：示例：使用 k-近邻算法改进约会网站的配对效果

通过收集的一些约会网站的数据信息，对匹配对象的归类：
不喜欢的人、魅力一般的人、极具魅力的人。

步骤

- 创建函数，以此来实现输入为**文件名字符串**，输出为**训练样本矩阵**和**类标签向量**。
- 分析可视化数据（实验内容1-2）
- 处理数据（归一化）
- 测试算法（实验内容1-3）

Step 1数据处理：数据存放在文本文件datingTestSet2.txt中，每个样本数据占据一行，总共有1000行。主要包含以下3种特征 （3:极具魅力，2：魅力一般的人，1：不喜欢的人）：

- 每年获得的飞行常客里程数
- 玩视频游戏所耗时间百分比
- 每周消费的冰淇淋公升数

40920	8.326976	0.953952	3
14488	7.153469	1.673904	2
26052	1.441871	0.805124	1
75136	13.147394	0.428964	1
38344	1.669788	0.134296	1
72993	10.141740	1.032955	1
35948	6.830792	1.213192	3
42666	13.276369	0.543880	3
67497	8.631577	0.749278	1
35483	12.273169	1.508053	3
50242	3.723498	0.831917	1
63275	8.385879	1.669485	1
5569	4.875435	0.728658	2
51052	4.680098	0.625224	1
77372	15.299570	0.331351	1
43673	1.889461	0.191283	1

- 数据处理：在kNN.py模块，创建名为file2matrix的函数，以此来处理输入格式问题。该函数的输入为**文件名字符串**，输出为**训练样本矩阵**和**类标签向量**。
- readlines() 方法用于读取所有行(直到结束符 EOF)并返回列表。

```
def file2matrix(filename):
    fr = open(filename)
    numberOfLines = len(fr.readlines())
    returnMat = zeros((numberOfLines,3))
    classLabelVector = []
```

- strip()表示删除掉数据中的换行符
- split()按照**制表符**分割字符串（tab字符\t）
- append() 方法用于在列表末尾添加新的对象。

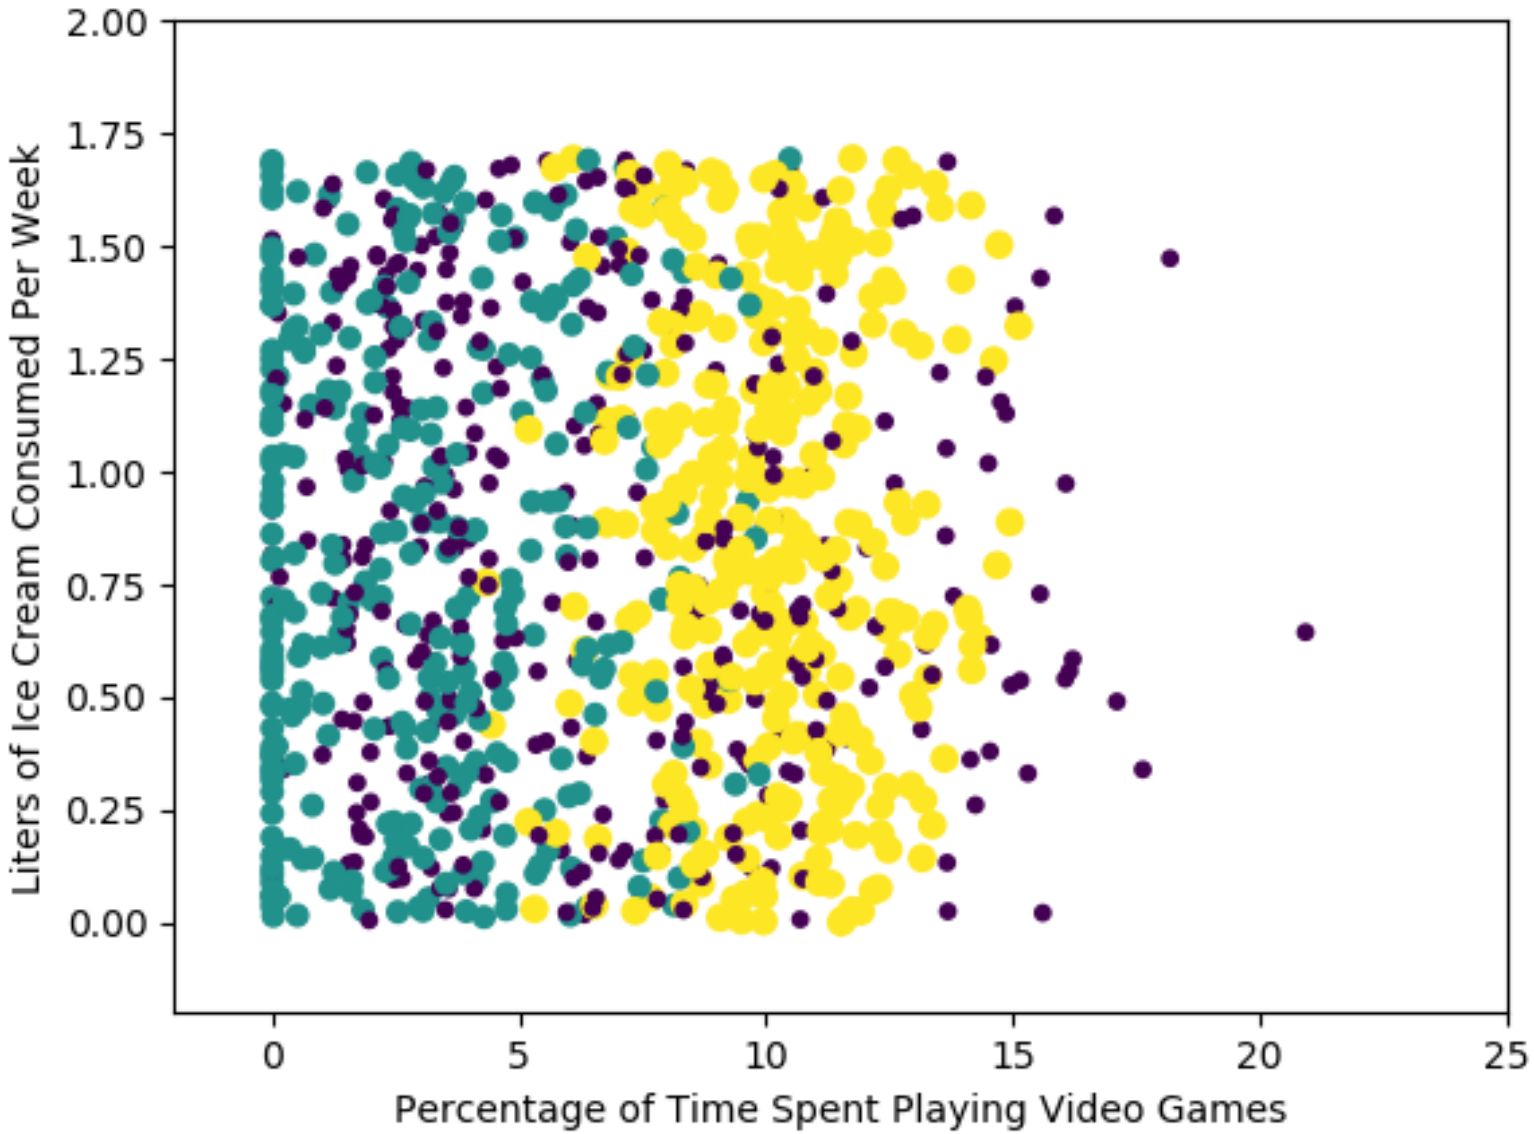
```
    fr = open(filename)
    index = 0
    for line in fr.readlines():
        line = line.strip()
        listFromLine = line.split('\t')
        returnMat[index,:] = listFromLine[0:3]
        classLabelVector.append(int(listFromLine[-1]))
        index += 1
    return returnMat,classLabelVector
```

Step 2分析数据：使用Matplotlib显示数据点

实验1-2：

- 编写程序，创建名Data_display.py的模块，利用file2matrix函数，导入datingTestSet2.txt文件数据；
- 利用matplotlib中的plt、scatter函数画图，直观显示数据信息（每年获得的飞行常客里程数、玩视频游戏所耗时间百分比、每周消费的冰淇淋公升数三类信息任取两种）对标签的影响；

- 示例：玩视频游戏所耗时间百分比、每周消费的冰淇淋公升数对标签的影响。



Step 3归一化数值

原因：飞行常客里程数对于计算结果的影响将远远大于表中其他两个特征；

$$\sqrt{(0-67)^2+(20\,000-32\,000)^2+(1.1-0.1)^2}$$

表2-3　约会网站原始数据改进之后的样本数据

	玩视频游戏所耗时间百分比	每年获得的飞行常客里程数	每周消费的冰淇淋公升数	样本分类
1	0.8	400	0.5	1
2	12	134 000	0.9	3
3	0	20 000	1.1	2
4	67	32 000	0.1	2

- 创建autoNorm函数将数字特征值转化为0到1的区间

```
newValue = (oldValue-min)/(max-min)
```

```
def autoNorm(dataSet):
    minVals = dataSet.min(0) # axis=0; 每列的最小值
    maxVals = dataSet.max(0)
    ranges = maxVals - minVals
    normDataSet = zeros(shape(dataSet))
    m = dataSet.shape[0]
    normDataSet = dataSet - tile(minVals, (m,1))
    normDataSet = normDataSet/tile(ranges, (m,1))   #element
wise divide
    return normDataSet, ranges, minVals
```

Step 4测试算法：

- 机器学习一般用已有数据的90%作为训练样本来训练分类器，而使用其余的10%数据去测试分类器，检测分类器的正确率。（kNN没有训练，我们用10%的数据作为测试）。

```
def datingClassTest():
    datingDataMat,datingLabels = file2matrix('datingTestSet2.txt')
    normMat, ranges, minVals = autoNorm(datingDataMat)

    XXXXXX
```

实验1-3：编写程序，利用classify0函数（k=3）；实现datingTestSet2.txt中10% 数据的测试，并打印出测试结果结果及准确率；