

Topic 2 分类与回归

Part 2：回归模型

魏准
浙江大学，信息与电子工程学院

总体内容

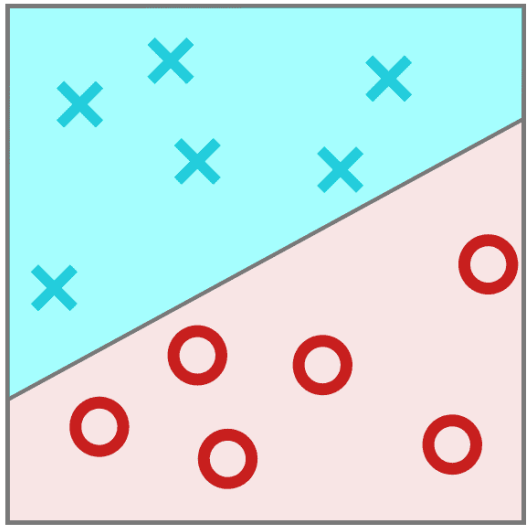
回归：A statistical technique for estimating the relationships among variables.

举例：假设现在有一些数据点，我们用一条线对这些点进行拟合（该线称为最佳拟合直线），这个拟合过程就称作回归。

主要知识点

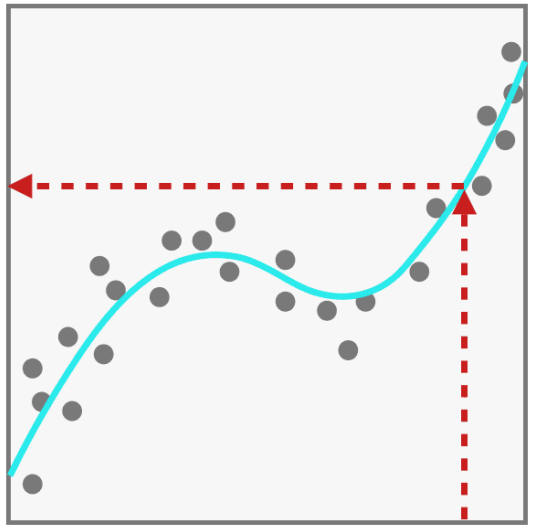
- 标准方程；
- 多项式回归；
- 逻辑回归（Logistic/Logit Regression）。

Classification Groups observations into "classes"



Here, the line classifies the observations into X's and O's

Regression predicts a numeric value



Here, the fitted line provides a predicted output, if we give it an input

1.1：线性回归

线性模型：对输入特征加权求和，再加上一个偏置项的常数，以此预测。

线性回归模型预测：

$$\hat{y} = \theta_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$$

- $\hat{y}$ is the predicted value.
- n is the number of features.
- x_i is the ith feature value.
- θ_j is the jth model parameter (including the bias term θ_0 and the feature weights $\theta_1, \theta_2, \cdots, \theta_n$).

线性模型预测（向量化形式）：

$$\hat{y} = h_{\boldsymbol{\theta}}(\mathbf{x}) = \boldsymbol{\theta} \cdot \mathbf{x}$$

- $\boldsymbol{\theta}$ is the model's *parameter vector*, containing the bias term θ_0 and the feature weights θ_1 to θ_n.
- $\mathbf{x}$ is the instance's *feature vector*, containing x_0 to x_n, with x_0 always equal to 1.
- $\boldsymbol{\theta} \cdot \mathbf{x}$ is the dot product of the vectors $\boldsymbol{\theta}$ and $\mathbf{x}$, which is of course equal to $\theta_0 x_0 + \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_n x_n$.
- $h_{\boldsymbol{\theta}}$ is the hypothesis function, using the model parameters $\boldsymbol{\theta}$.

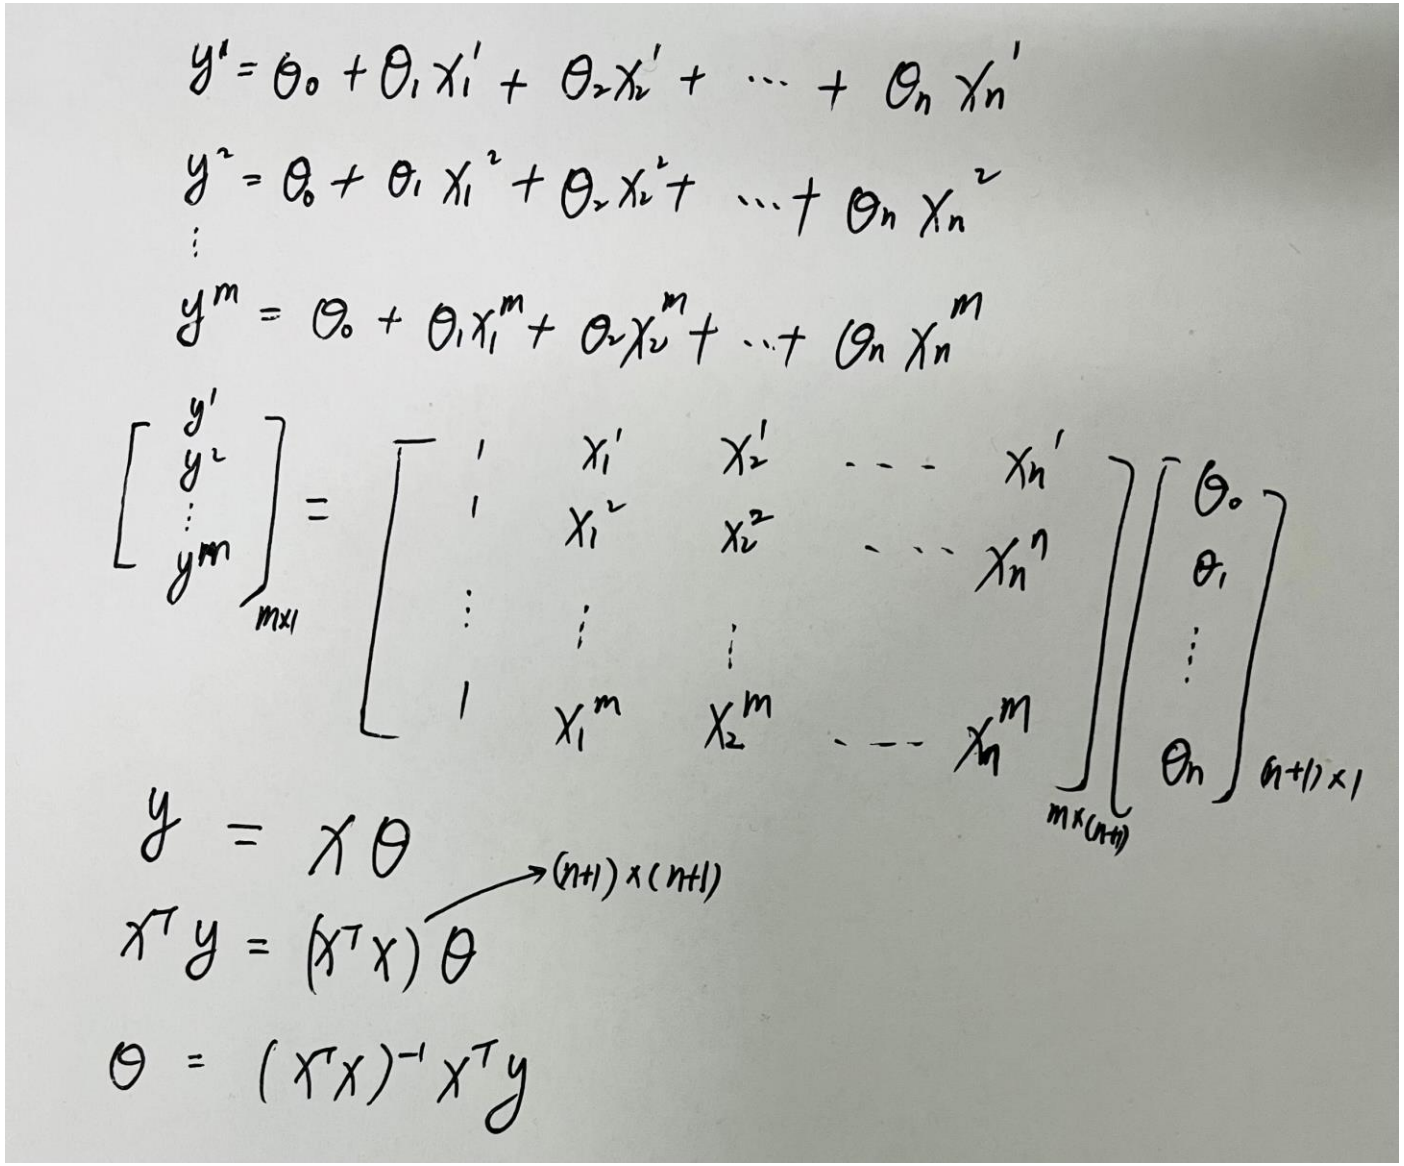
闭式解解法：直接得出结果的数学方程

标准方程解：

$$\widehat{\boldsymbol{\theta}} = \left(\mathbf{X}^T\mathbf{X}\right)^{-1} \quad \mathbf{X}^T \quad \mathbf{y}$$

- $\widehat{\boldsymbol{\theta}}$ is the value of $\boldsymbol{\theta}$ that minimizes the cost function.
- $\mathbf{y}$ is the vector of target values containing $y^{(1)}$ to $y^{(m)}$.

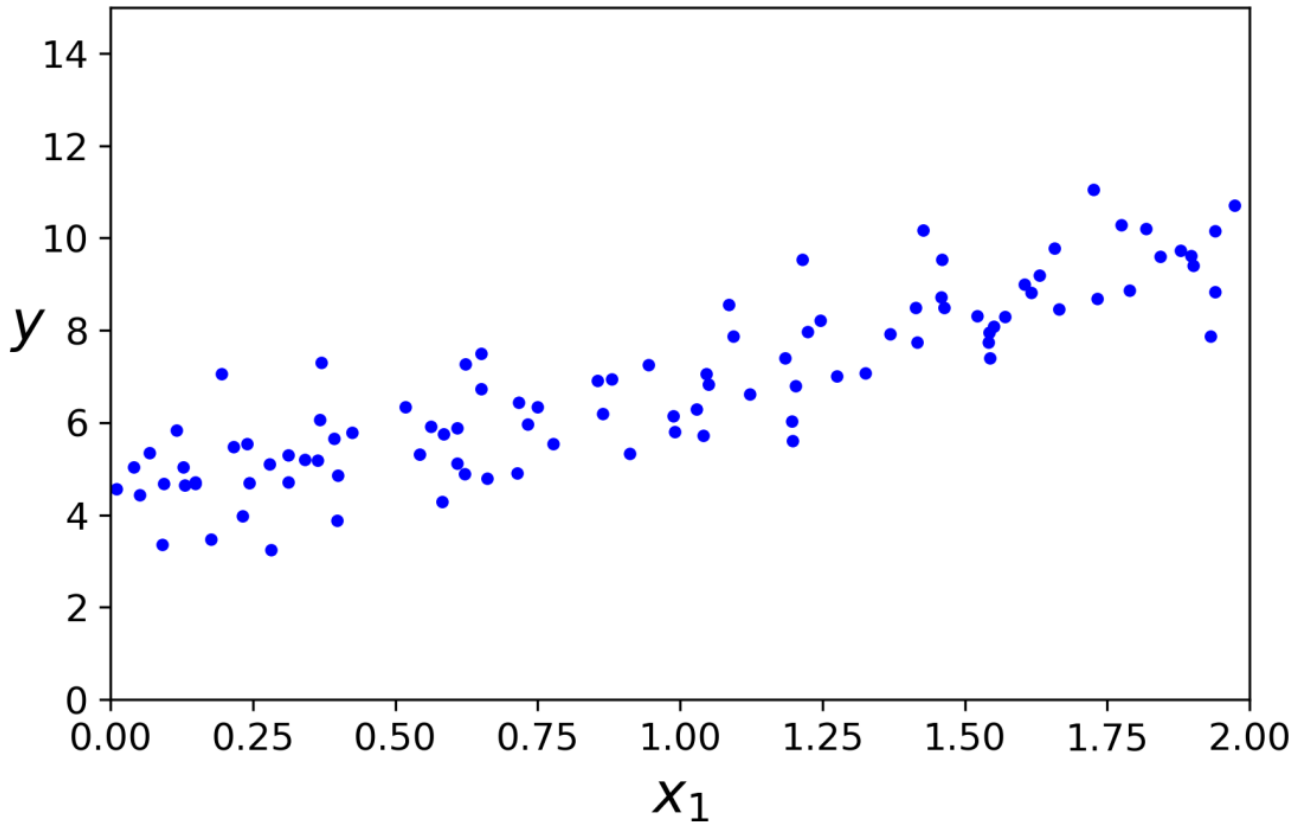
具体解法：最小二乘法（Least square method）



代码验证：m? n?

高斯噪声

```
import numpy as np
X = 2 * np.random.rand(100, 1)
y = 4 + 3 * X + np.random.randn(100, 1)
```

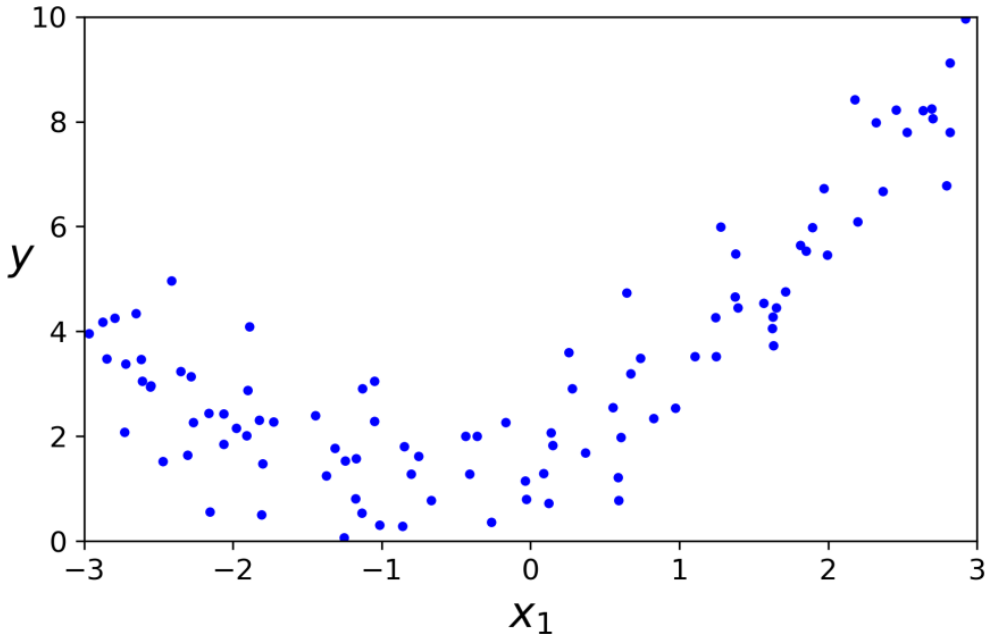


实验2-1：编写程序，通过上一页产生的附加噪声的随机数据，（1）做线性回归（即求出 θ ）；（2）利用取得的回归模型，对x=0和x=2两个点做预测；（3）对上述随机数据和预测结果利用plot可视化。

1.2：多项式回归

背景：数据比较复杂，不能用直线描述，但仍希望用线性模型拟合非线性数据；
方法：每个特征的幂次方添加为一个新特征，在此拓展特征集上训练一个线性模型，即**多项式回归**

```
m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)
```



无法用一条直线拟合！！

使用Scikit-Learn：利用PolynomialFeatures类来转换训练数据，将训练集中每个特征的平方添加为新特征：

- Step 1：在终端用pip install -U scikit-learn 安装工具
- Step 2：利用PolynomialFeatures定义多项式的级数
- Step 3：利用poly_features.fit_transform产生新的X_poly，其中X（size:100*1）、X_poly（size:100*2）

```
import numpy as np
m = 100
X = 6 * np.random.rand(m, 1) - 3
y = 0.5 * X**2 + X + 2 + np.random.randn(m, 1)

from sklearn.preprocessing import PolynomialFeatures
poly_features = PolynomialFeatures(degree=2,
include_bias=False)
X_poly = poly_features.fit_transform(X)
```

实验2-2：通过网上调研了解Scikit-Learn中的LinearRegression模块，编写程序，利用LinearRegression模块：（1）对上述产生的二级多项式数据（X_poly, y) 做线性回归。(2) 可视化回归模型和数据。

```
from sklearn.linear_model import LinearRegression

XXXX
```

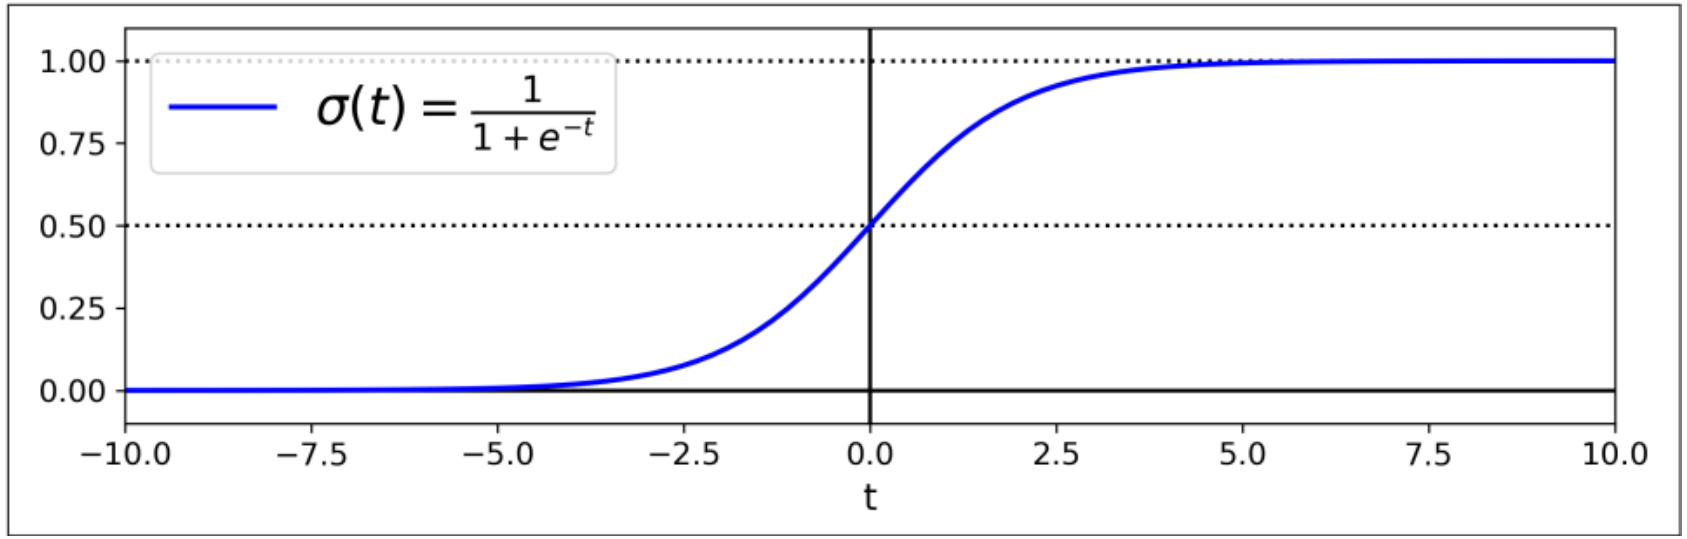
1.3：逻辑回归（Logistic/Logit Regression）

用途：用于估算一个实例属于某个特定类别的**概率**，如一封电子邮件属于垃圾邮件的概率是多少。

与分类的联系：如预估概率超过50%，这模型预测该实属于该类别（标记为1）；反之，则预测不是（标记为0）-相当于一个二元分类器。

向量化的估计概率：$\hat{p} = h_{\boldsymbol{\theta}}(\mathbf{x}) = \sigma\left(\mathbf{x}^T\boldsymbol{\theta}\right)$

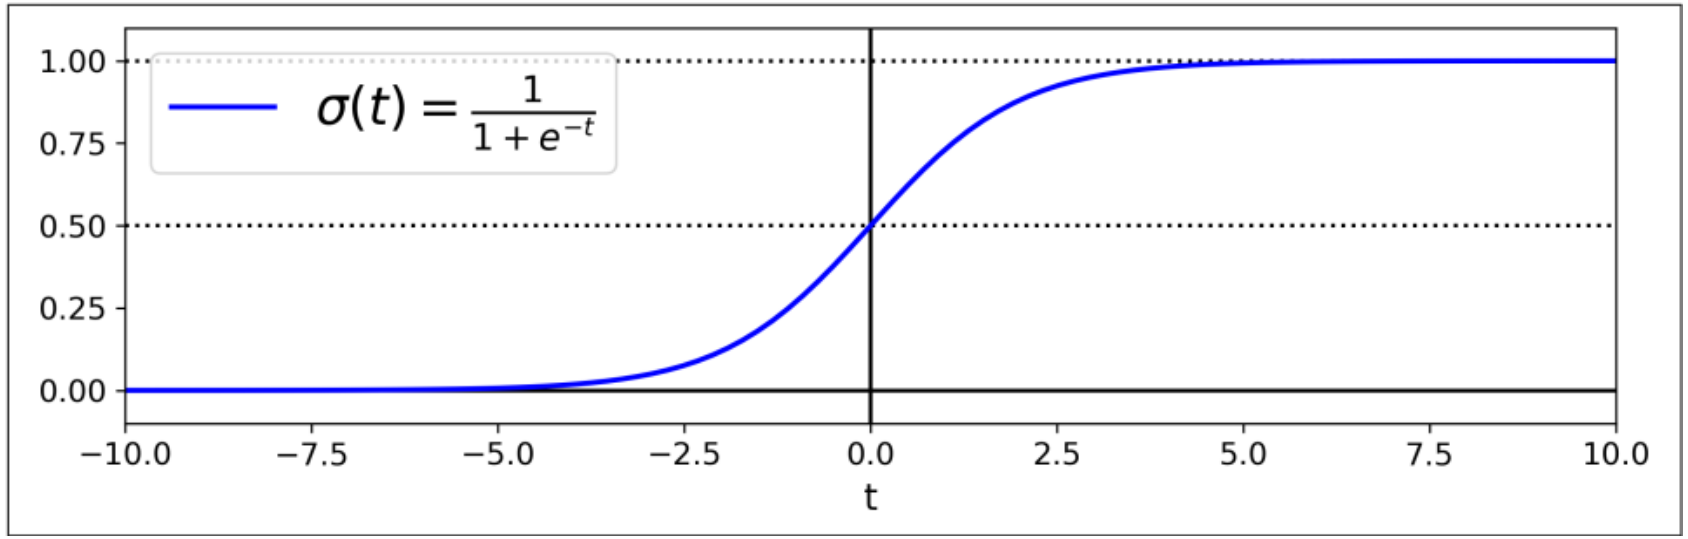
$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$



相当于在线性模型下，加一个非线性激活函数 sigmoid function

逻辑回归模型预测

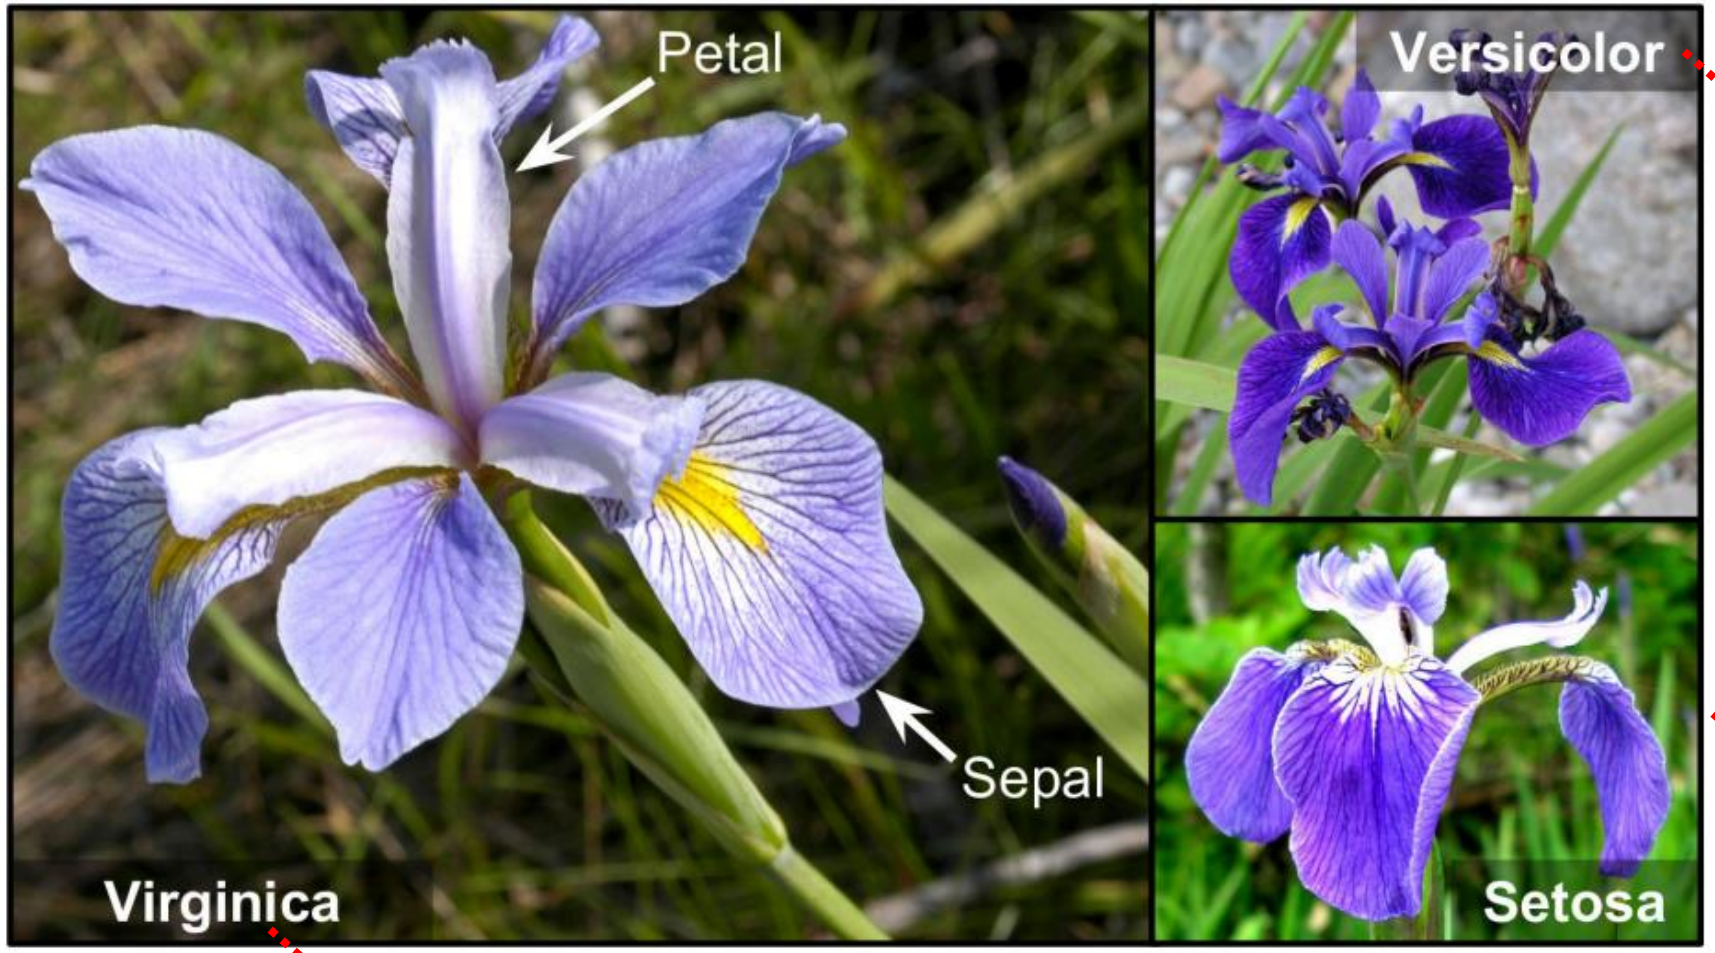
$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$



$$\hat{y} = \begin{cases} 0 \text{ if } \hat{p} < 0.5 \\ 1 \text{ if } \hat{p} \geq 0.5 \end{cases}$$

Notice that $\sigma(t) < 0.5$ when $t < 0$, and $\sigma(t) \geq 0.5$ when $t \geq 0$, so a Logistic Regression model predicts 1 if $\mathbf{x}^T \boldsymbol{\theta}$ is positive, and 0 if it is negative.

鸢尾植物逻辑回归实例：150朵、三个品种，数据中包含花的萼片及花瓣长度和宽度;



变色鸢尾

山鸢尾

维吉亚鸢尾

实验2-3：以花瓣宽度为特征，创建一个分类器检测维吉亚鸢尾花：

a) 查阅网上资料，通过sklearn.linear_model中的LogisticRegression实现一个分类器检测维吉亚鸢尾花。

```
import numpy as np
from sklearn import datasets
iris = datasets.load_iris()
list(iris.keys())
print(list(iris.keys())) #['data', 'target', …]
X = iris["data"][:, 3:] # petal width
y = (iris["target"] == 2).astype(int)
from sklearn.linear_model import LogisticRegression

XXXX
```

实验2-3：以花瓣宽度为特征，创建一个分类器检测维吉亚鸢尾花：

b) 利用LogisticRegression.predict_proba函数，可视化花瓣宽度为0-3 cm之间的鸢尾花，模型估算为维吉亚鸢尾花的概率。

c) 利用LogisticRegression.predict函数，判断花瓣宽度分别为1.7和1.5是/否属于维吉亚鸢尾花