

Topic 2 分类与回归

Part 3：支持向量机（SVM）-线性可分数据

魏准
浙江大学，信息与电子工程学院

总体内容

支持向量机（SVM）-线性可分数据

主要知识点

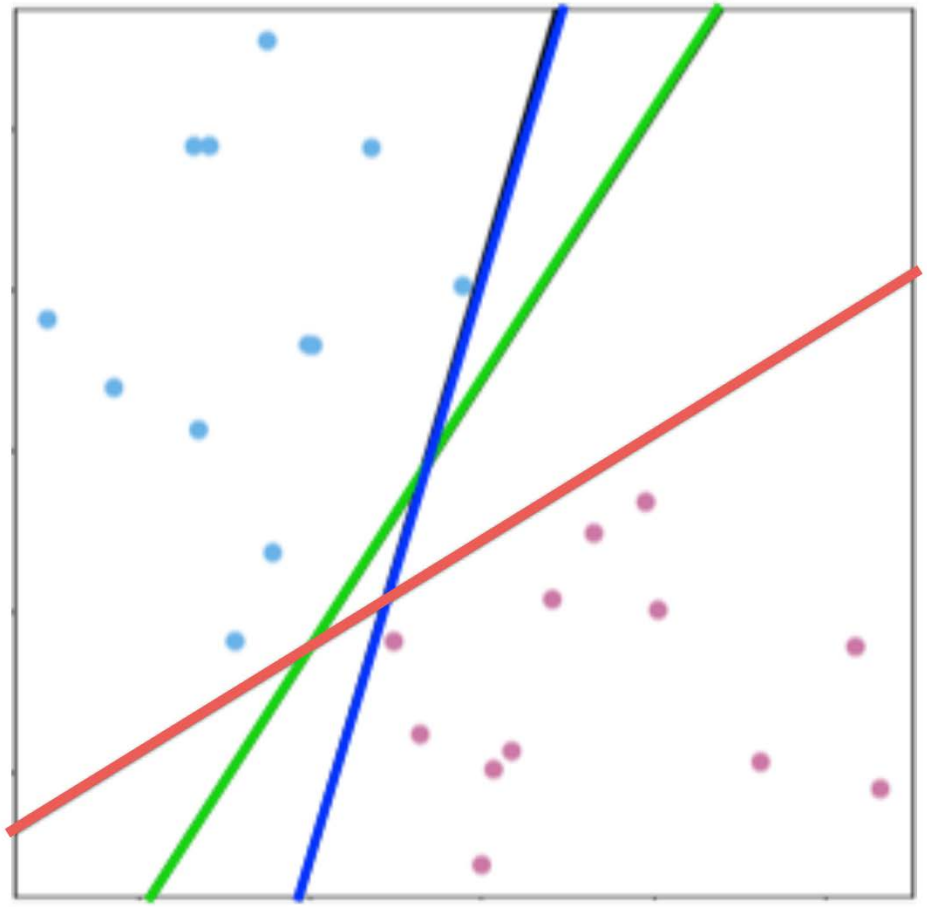
- 问题描述；
- 超平面；
- 最大间隔；
- 如何找到最大间隔超平面；
- 软间隔；
- SVM实例

参考教材：

1、机器学习， 周志华，清华大学出版社，2016.
2、机器学习实战，Peter Harrington, 人民邮电出版社，2013.
3、机器学习实战-基于Scikit-Learn、Keras和TensorFlow，Aurelien Geron，机械工业出版社.
4、Pavlos Protopapas and Kevin Rader, CS109A Introduction to Data Science.
5、Sherrie Wang, CME 250: Introduction to Machine Learning

支持向量机（SVM）-线性可分数据

问题描述：给定训练样本集$D=\{(x_1,y_1),(x_2,y_2),\cdots(x_m,y_m)\}$，$y_m \in \{-1,+1\}$。基于训练集D，在样本空间中找到一个划分**超平面**，将不同类别的样本分开，如何找到这个**超平面**？

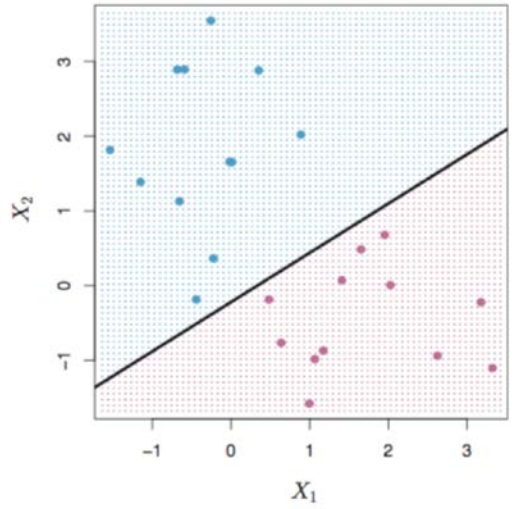


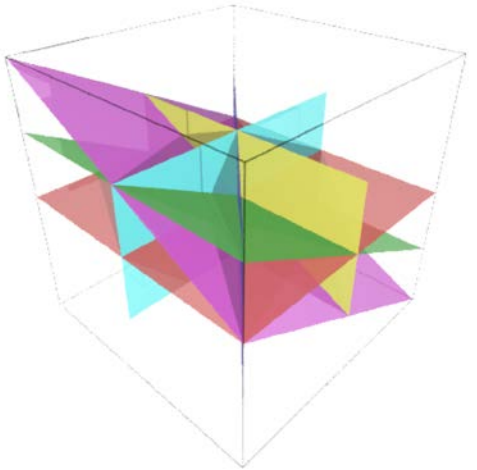
2.1 超平面（Hyperplane）

定义：在*P*-维空间中，超平面是指(*P-1*)-维子空间；即2D空间的超平面是1D空间（直线），3D空间的超平面是2D空间（平面）

数学定义：2D空间超平面（直线）

$$\beta_0 + \beta_1 X_1 + \beta_2 X_2 = 0$$





数学定义：任意*P*-维空间超平面

$$\beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p = 0$$

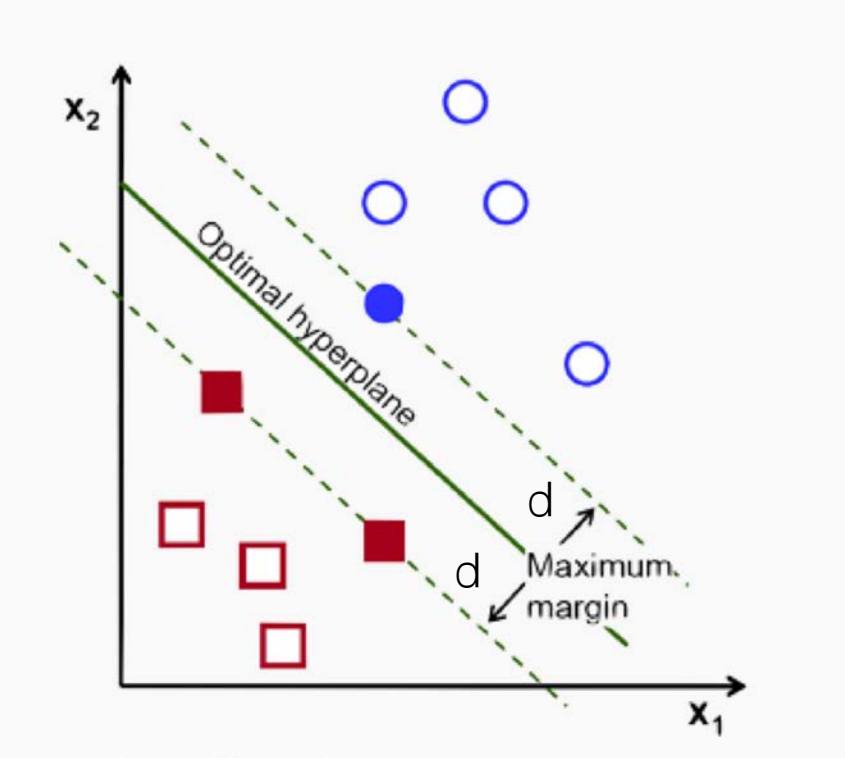
对于一个样本X，下面两个式子分别表示在超平面**不同两侧**的样本

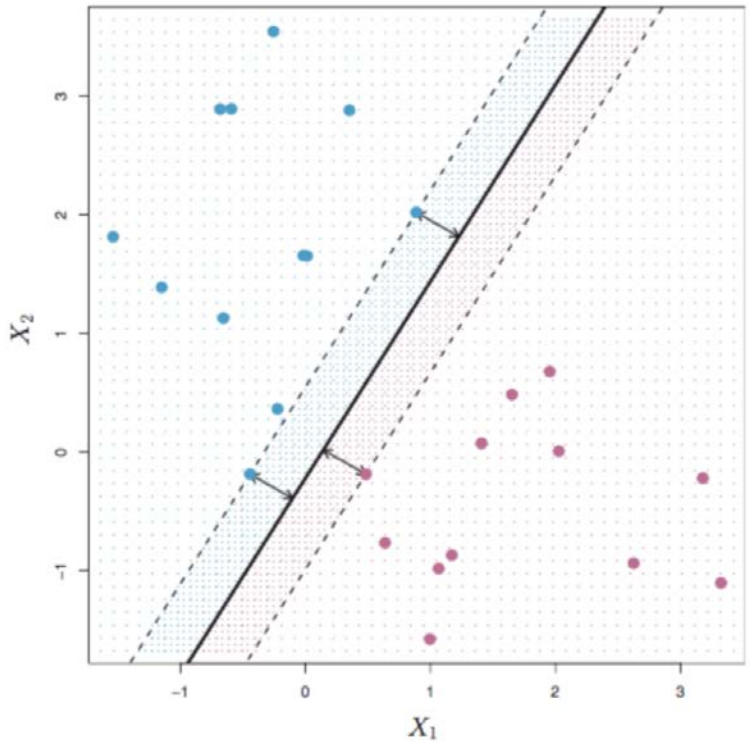
$$\beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p > 0$$

$$\beta_0 + \beta_1 X_1 + \ldots + \beta_p X_p < 0$$

2.2 最大间隔（Maximizing Margins）

- **间隔：**任意训练样本和超平面的**最小距离；**
- **支持向量（Support Vector）**： 训练样本中与超平面距离等于**间隔d**的样本。
  - ✓ 支持（Support）:最大间隔超平面只取决于这些点;
  - ✓ 向量（Vector）： 这些样本点是*P*-维向量;

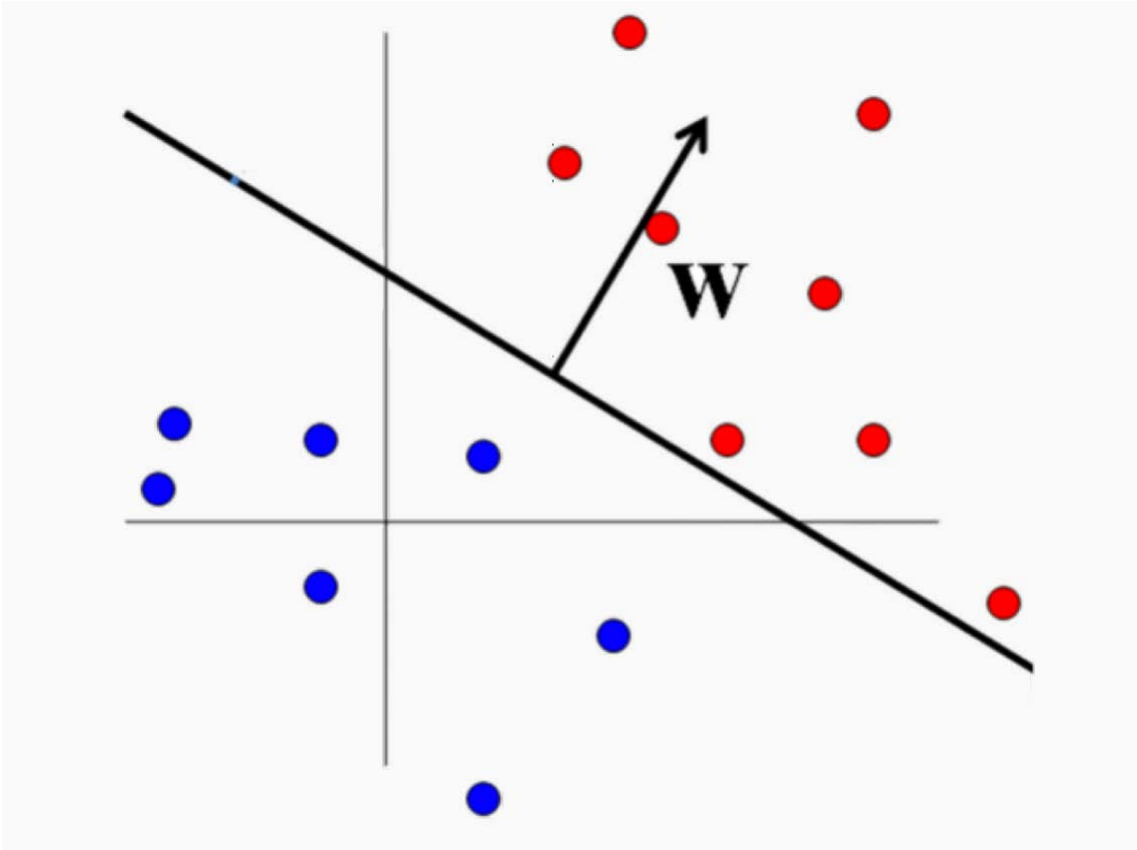




2.3 如何找到最大间隔超平面

- **任意线性超平面定义：** $w^T x + b = 0$

- n维空间($x_1, x_2, \cdots, x_n$), 到超平面的**距离d：** $\frac{|w^T x + b|}{||w||}$ $||w|| = \sqrt{w_1^2 + \ldots w_n^2}$



$$\begin{cases} \frac{w^T x + b}{||w||} \geq d & y = 1 \\ \frac{w^T x + b}{||w||} \leq -d & y = -1 \end{cases}$$

2.3 如何找到最大间隔超平面

$$\begin{cases} \dfrac{w^T x + b}{||w||} \geq d & y = 1 \\ \dfrac{w^T x + b}{||w||} \leq -d & y = -1 \end{cases}$$

除以
正数d

$$\begin{cases} \dfrac{w^T x + b}{||w||d} \geq 1 & y = 1 \\ \dfrac{w^T x + b}{||w||d} \leq -1 & y = -1 \end{cases}$$

令||w||d=1
优化问题不变

两边都乘||ω||d
通过b调整

$$\begin{cases} w^T x + b \geq 1 & y = 1 \\ w^T x + b \leq -1 & y = -1 \end{cases}$$

等效为

$$y(w^T x + b) \geq 1$$

$$d = \frac{|w^T x + b|}{||w||}$$

$y(w^T x + b) = |w^T x + b|$

由于左边大于0,
对左边取绝对值,
得到右边

$$d = \frac{y(w^T x + b)}{||w||}$$

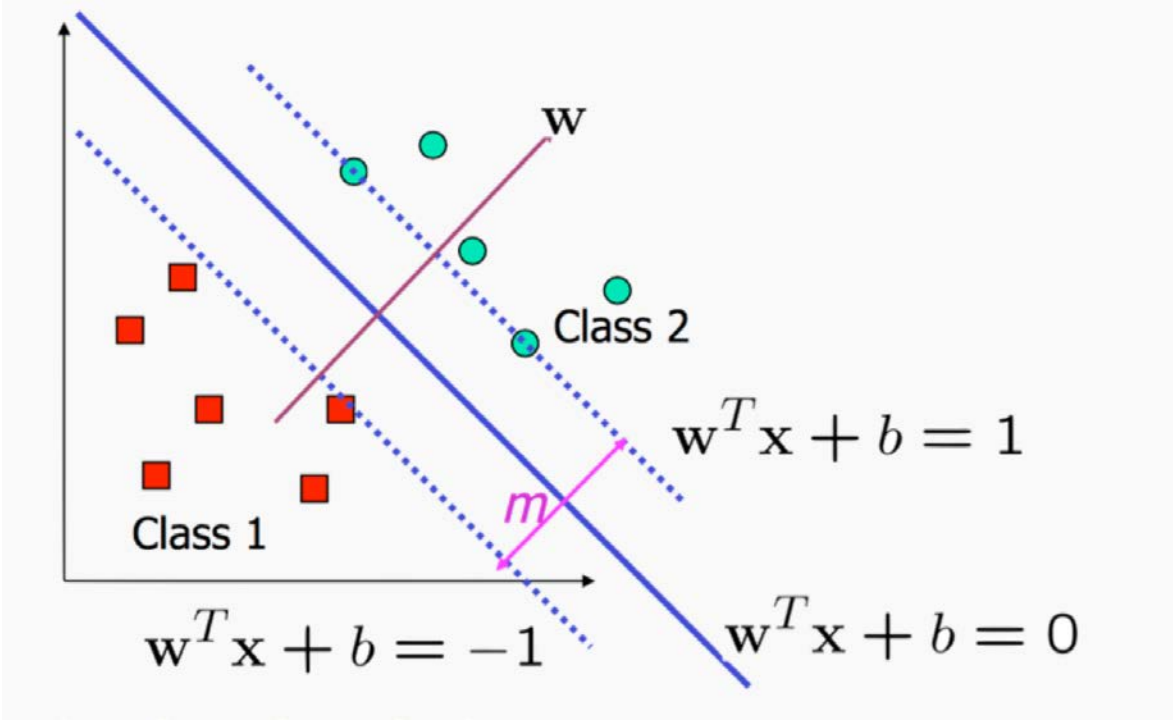
等效为

$$\max 2 * \frac{y(w^T x + b)}{||w||}$$

2.3 如何找到最大间隔超平面

$$d = \frac{y(w^T x+b)}{||w||} \quad , \quad ||w||d=1 \Longrightarrow y(w^T x + b) = 1 \Longrightarrow \max 2 * \frac{y(w^T x+b)}{||w||} \Longrightarrow \max \frac{2}{||w||}$$

$$\Longrightarrow \min \frac{1}{2}||w|| \Longrightarrow \boxed{\min \frac{1}{2}||w||^2 \quad s.t. \quad y_i\left(w^T x_i + b\right) \geq 1}$$



2.4 软间隔

■ **软间隔：** 允许个别点出现在间隔带里面（针对在实际应用中，完全线性可分的情况很少）

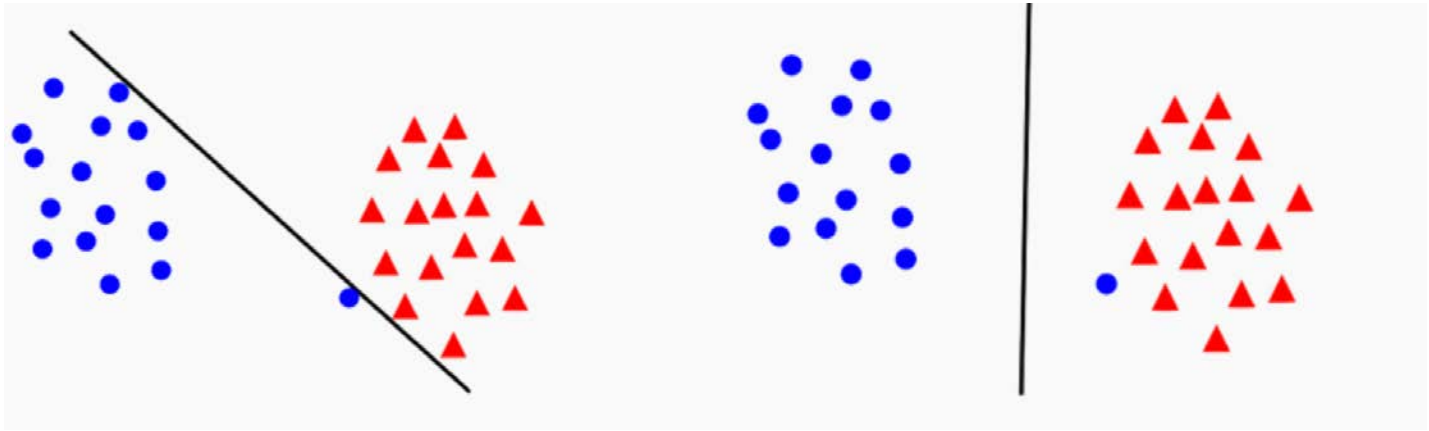
$$\min \frac{1}{2}||w||^2 \quad s.t. \quad y_i（w^T x_i + b） \geq 1$$

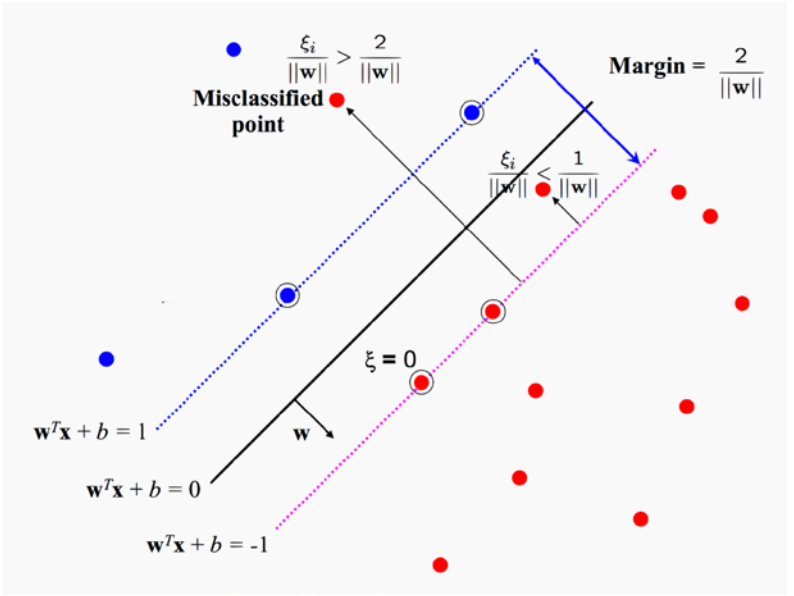
$$\min_w \frac{1}{2}||w||^2 + C\sum_{i=1}^{m}\xi_i$$

$$s.t. \quad g_i(w,b) = 1 - y_i(w^T x_i + b) - \xi_i \leq 0,$$

$$\xi_i \geq 0, \quad i = 1, 2, \ldots, n$$

C为大于0的常数；
C为有限值时，软间隔起作用
C无穷大时，要求ξ_i无穷小，软间隔无用





2.5：SVM实例

- 使用Scikit-Learn 中的**SVM**模型，根据花瓣长度、花瓣宽度，实现鸢尾花数据集分类，以检测**维吉尼亚鸢尾花**：
  ① 加载鸢尾花数据集；
  ② 缩放特征；
  ③ 训练线性SVM模型；
  ④ 测试监测鸢尾花特征（**花瓣长度、花瓣宽度**）为（4-6，0.8-2.5）的分类情况；
  ⑤ 可视化结果；
  ⑥ 实现C取值0.5、1、15、30、50、100的结果，分析结果、总结结论。
  ⑦ 可视化不同C值结果。

2.5：SVM实例

```
import numpy as np
from sklearn import datasets
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import LinearSVC
iris = datasets.load_iris()    # 导入数据;
X = iris[“data”][:, (2, 3)]     # 长度特征、宽度特征;
y = (iris[“target”] == 2).astype(np.float64)  # 判断是否为维吉尼亚鸢尾花，若target=2，则y=1;
svm_clf = Pipeline([
                    XXXXXXXXXXXXX,  #查询Pipeline函数，采用StandardScaler、LinearSVC、hinge损失函数
                    ])  #模型设置
svm_clf.fit(X, y)        #模型训练
svm_clf.predict([[XXX, XXX]])     #模型测试（长度特征、宽度特征）
```