

Topic 2 分类与回归

Part 3：非线性支持向量机（SVM）

魏准
浙江大学，信息与电子工程学院

总体内容

非线性支持向量机

主要知识点

- 线性支持向量机（SVM）-拉格朗日函数；
- 线性支持向量机（SVM）-对偶性；
- 线性支持向量机（SVM）-序列最小优化算法；
- 支持向量机（SVM）-非线性分类；
- 非线性SVM-核函数;
- 非线性SVM-多项式核函数。

参考教材：

1、机器学习， 周志华，清华大学出版社，2016.
2、机器学习实战，Peter Harrington, 人民邮电出版社，2013.
3、机器学习实战-基于Scikit-Learn、Keras和TensorFlow，Aurelien Geron，机械工业出版社.
4、Pavlos Protopapas and Kevin Rader, CS109A Introduction to Data Science.
5、Sherrie Wang, CME 250: Introduction to Machine Learning

3.1线性支持向量机（SVM）-拉格朗日函数

$$\min_{w} \frac{1}{2}||w||^2 + C\sum_{i=1}^{m}\xi_i$$

$$s.t. \quad g_i(w,b) = 1 - y_i(w^T x_i + b) - \xi_i \leq 0,$$

$$\xi_i \geq 0, \quad i = 1, 2, \ldots, n$$

构造拉格朗日函数

$$\min_{w,b,\xi} \max_{\lambda,\mu} L(w,b,\xi,\lambda,\mu) = \frac{1}{2}||w||^2 + C\sum_{i=1}^{m}\xi_i + \sum_{i=1}^{n}\lambda_i[1 - \xi_i - y_i(w^T x_i + b)] - \sum_{i=1}^{n}\mu_i\xi_i$$

拉格朗日乘子

$$s.t. \quad \lambda_i \geq 0 \quad \mu_i \geq 0$$

3.1线性支持向量机（SVM）-对偶性

$$\min_{w,b,\ \xi_i}\max_{\lambda,\mu} L(w,b,\xi,\lambda,\mu) = \frac{1}{2}||w||^2 + C\sum_{i=1}^{m}\xi_i + \sum_{i=1}^{n}\lambda_i[1-\xi_i - y_i(w^T x_i + b)] - \sum_{i=1}^{n}\mu_i\xi_i$$

拉格朗日乘子

$$s.t. \quad \lambda_i \geq 0 \quad \mu_i \geq 0$$

⇩ 对偶性

$$\max_{\lambda,\mu}\min_{w,b,\ \xi_i} L(w,b,\ \xi_i,\lambda,\mu)$$

3.1线性支持向量机（SVM）-序列最小优化算法

$$\max_{\lambda,\mu} \min_{w,b,\ \xi_i} L(w, b,\ \xi_i, \lambda, \mu)$$

对ω、b、ξ_i偏导=0

$$w = \sum_{i=1}^{m} \lambda_i y_i x_i$$

$$0 = \sum_{i=1}^{m} \lambda_i y_i$$

$$C = \lambda_i + \mu_i$$

$$\min_{w,b,\ \xi_i} L(w, b,\ \xi_i, \lambda, \mu) = \sum_{j=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)$$

与μ无关

$$\max_{\lambda} [\sum_{j=1}^{n} \lambda_i - \frac{1}{2} \sum_{i=1}^{n} \sum_{j=1}^{n} \lambda_i \lambda_j y_i y_j (x_i \cdot x_j)]$$

$$s.t. \quad \sum_{i=1}^{n} \lambda_i y_i = 0, \quad \lambda_i \geq 0, \quad C - \lambda_i - \mu_i = 0$$

- 序列最小优化算法-SMO(Sequential Minimal Optimization)优化，求出λ（参考文献2）；

$$w = \sum_{i=1}^{m} \lambda_i y_i x_i$$

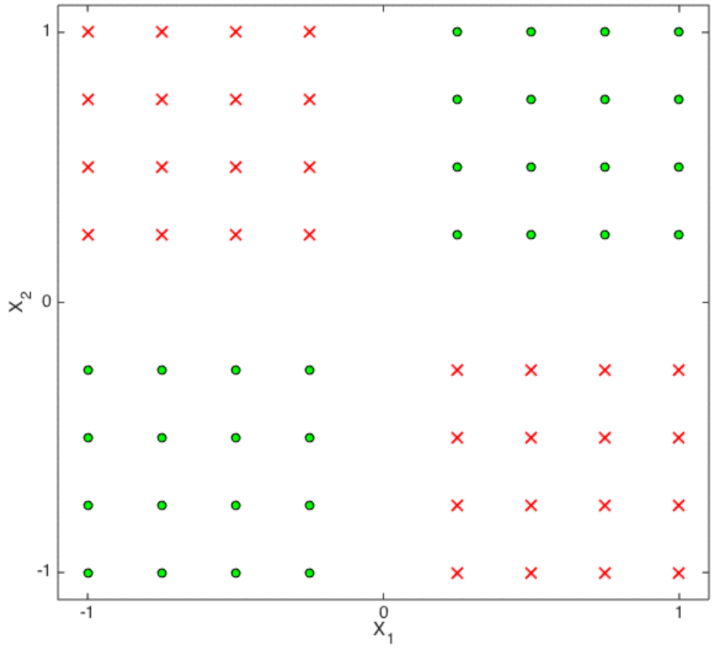
$$b = \frac{1}{|S|} \sum_{s \in S} (y_s - w x_s)$$

$$w^T x + b = 0$$

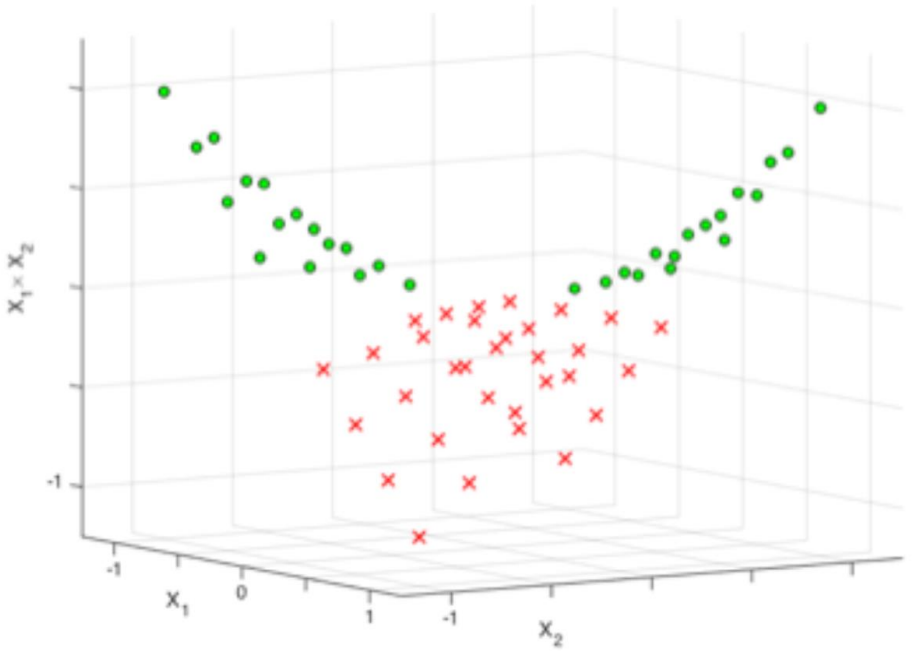
3.2 支持向量机（SVM）-非线性分类

- **问题描述：**给定训练样本集D={$(x_1,y_1),(x_2,y_2),\cdots(x_m,y_m)$}，$y_m \in \{-1,+1\}$。基于训练集D，在样本空间中找到一个划分**超平面**，将不同类别的样本分开，如何找到这个**超平面**？

- **解决办法：**将线性不可分样本映射到**高维空间**中，让样本点在**高维空间线性可分**



variables x_1, x_2

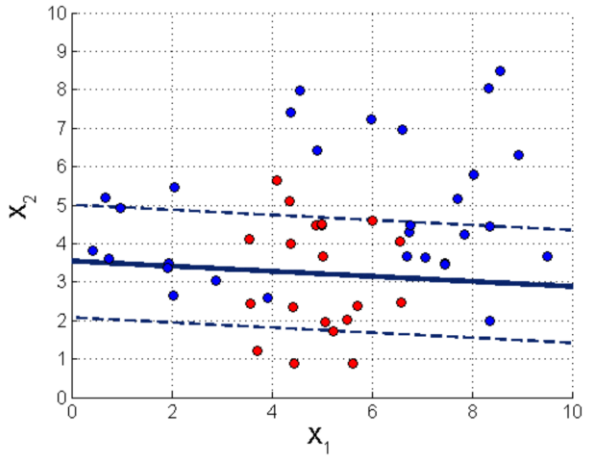


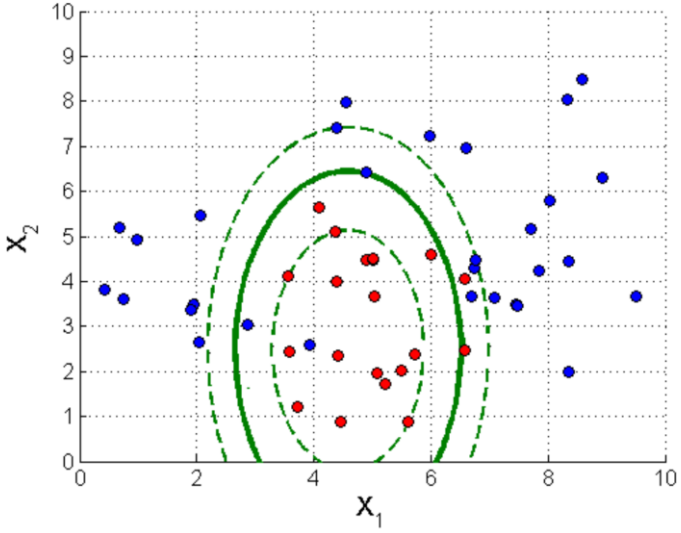
variables x_1, x_2, x_1x_2

3.3 整体思路：特征拓展

- 原特征为p维度

$$\vec{X} = (X_1, X_2, \ldots, X_p)$$





- 以拓展为2p维度为例

$$\vec{\tilde{X}} = (X_1, X_1^2, X_2, X_2^2, \ldots, X_p, X_p^2)$$

$$= (\tilde{X}_1, \tilde{X}_2, \tilde{X}_3, \tilde{X}_4, \ldots, \tilde{X}_{2p-1}, \tilde{X}_{2p})$$

- 超平面与原始特征为非线性关系

$$\beta_0 + \beta_1 X_1 + \beta_2 X_1^2 + \ldots + \beta_{2p-1} X_p + \beta_{2p} X_p^2 = 0$$

3.4：实验1：SVM-非线性数据分类

- 使用Scikit-Learn 线性分类器、多项式特征对非线性数据分类 。

① 产生非线性数据集;

② 利用Pipeline函数构建线性分类器;

③ 利用Pipeline函数的PolynomialFeatures函数产生非线性特征;

④ 利用Pipeline函数的StandardScaler标准化数据;

⑤ 利用Pipeline函数的LinearSVC构建线性分类;

⑥ 利用polynomial_svm_clf.fit 训练数据

⑦ 可视化训练数据

⑧ 测试数据

⑨ 讨论分析不同非线性特征（2阶、3阶、8阶）的结果

⑩ 讨论分析C=1、10、100的结果

3.4：实验1：SVM-非线性数据分类

```
from sklearn.datasets import make_moons
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import LinearSVC
from sklearn.preprocessing import PolynomialFeatures
import matplotlib.pyplot as plt
from sklearn.metrics import classification_report, confusion_matrix
X, y=make_moons(n_samples=100, noise=0.15) # 导入数据;
polynomial_svm_clf = Pipeline([
        ("poly_features", XXXXXX), # 产生非线性特征
        ("scaler", XXXXXX),  #采用StandardScaler标准化数据
        ("svm_clf", XXXXXX)  #采用LinearSVC模型，hinge 损失函数
    ])
polynomial_svm_clf.fit(X, y))   # 训练模型
svm_clf.predict([[XXX, XXX]])     #模型测试
#数据可视化
```

3.5 核函数

- 低维空间映射到高维空间后维度会很大，若将全部样本的点乘全部计算好，计算量太、内存大。

- **核函数**：广义内积。该运算接收两个输入参数，并在某个特征空间中**隐式地**计算它们的内积，**核函数k(x,y)=（ϕ_x, ϕ_y）**。

线性SVM-分割超平面

$$f(x)=\omega x+b$$

非线性SVM-分割超平面

$$f(x)=w\phi(x)+b$$

$$\max_{\lambda}[\sum_{j=1}^{n}\lambda_i-\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}\lambda_i\lambda_j y_i y_j(x_i\cdot x_j)]$$

$$s.t.\quad \sum_{i=1}^{n}\lambda_i y_i=0,\quad \lambda_i\geq 0,\quad C-\lambda_i-\mu_i=0$$

$$\max_{\lambda}[\sum_{j=1}^{n}\lambda_i-\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}\lambda_i\lambda_j y_i y_j(\phi(x_i)\cdot\phi(x_j))]$$

$$s.t.\quad \sum_{i=1}^{n}\lambda_i y_i=0,\quad \lambda_i\geq 0,\quad C-\lambda_i-\mu_i=0$$

3.6 常见核函数

- 线性核函数: $K(x, x') = \langle x, x' \rangle$
- 多项式核函数: $K(x, x') = (1 + \langle x, x' \rangle)^p$
- 高斯函数: $K(x, x') = \exp\left(-\gamma ||x - x'||^2\right)$

3.7：实验2：非线性SVM-核函数

- 使用Scikit-Learn 核函数分类器对非线性数据分类。
  - ① 产生非线性数据集（仍然采用上个实验数据）；
  - ② 利用Pipeline函数构建非线性分类器（多项式内核、“poly”函数）；
  - ③ 利用Pipeline函数的StandardScaler标准化数据;
  - ④ 利用Pipeline函数的SVC构建非线性分类;
  - ⑤ 利用polynomial_kernel_svm_clf.fit 训练数据;
  - ⑥ 可视化训练数据
  - ⑦ 测试数据
  - ⑧ 讨论分析C=1、10、100的结果;
  - ⑨ 讨论不同多项式阶数结果;
  - ⑩ 尝试不同核函数（如高斯核函数“rbf”）

3.7：实验2：非线性SVM-多项式核函数

```
from sklearn.datasets import make_moons
from sklearn.pipeline import Pipeline
from sklearn.svm import SVC
X, y=make_moons(n_samples=100, nois=0.15) # 导入数据;
poly_kernel_svm_clf = Pipeline([
        ("scaler", XXXXXX), #采用StandardScaler标准化数据
        ("svm_clf", XXXXXX)  # SVC构建非线性分类
        ])
polynomial_svm_clf.fit(X, y))   # 训练模型
svm_clf.predict([[XXX, XXX]])     #模型测试

#数据可视化
```