

Topic 3 降维技术
Part 1：主成分分析
（Principal Component Analysis， PCA）

魏准
浙江大学，信息与电子工程学院
2026

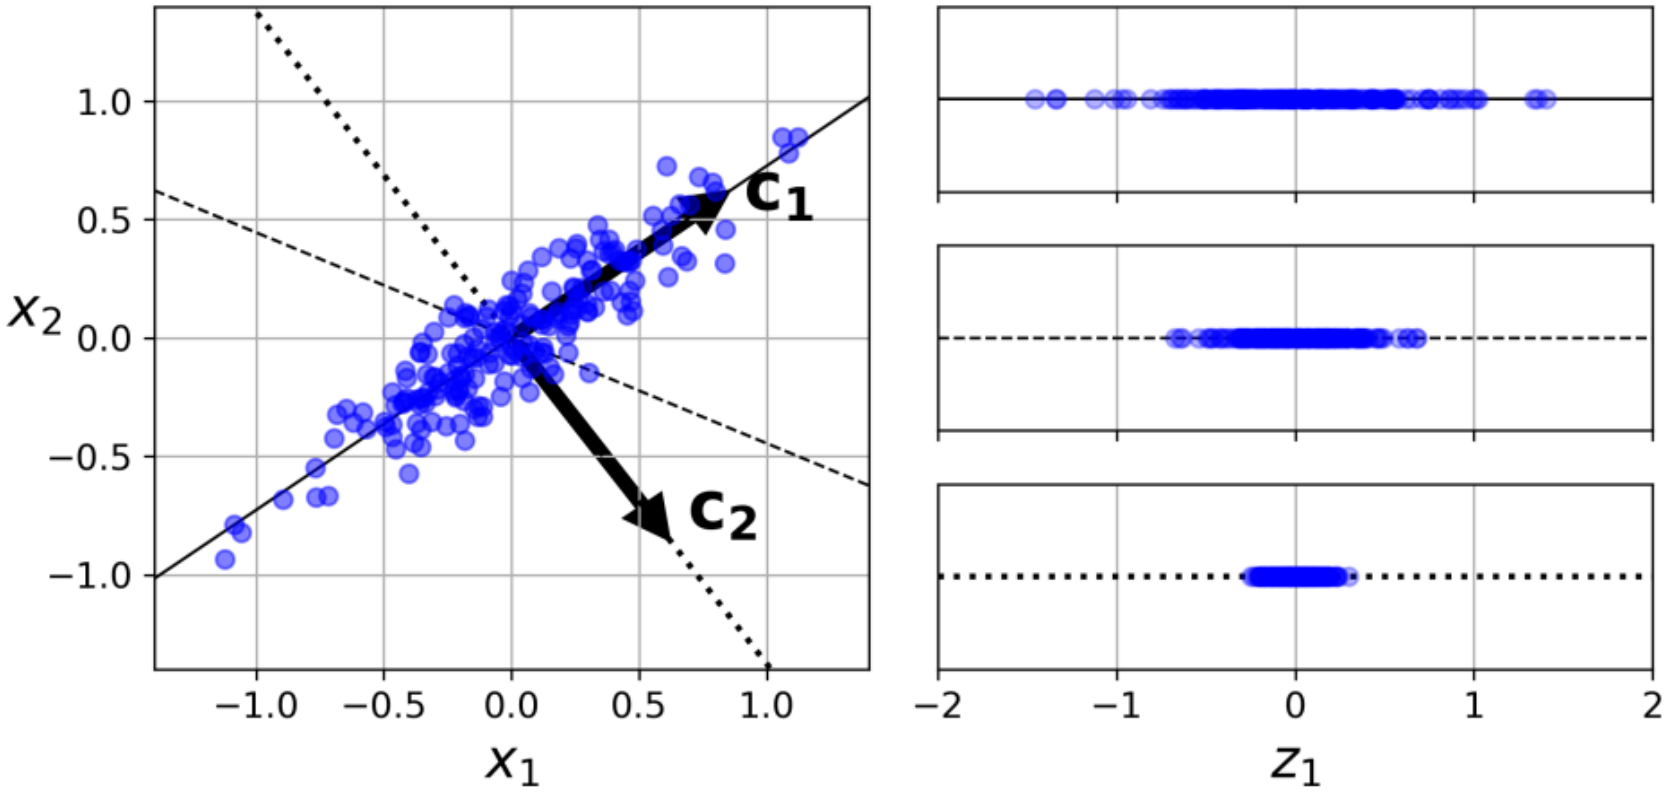
总体内容

降维技术目的：

- 使得数据集更易使用；
- 降低算法的计算开销；
- 去除噪声；
- 使得结果易懂。

主要知识点

- 主成分分析（Principal Component Analysis，PCA）；
- 代码实现；
- 实例降维处理；



PCA思想

- 在此实线上投影能够保留最大的差异性；
- 比其他线上投影能够实现信息丢失最少；
- 第二条轴（C2）与C1垂直（正交），其对剩余的数据差异性贡献最大；
- 如果有更高的维度，即可找出与前面两条都正交的第三条轴，以此类推，可找出其他维度。
- 第n个轴称作第n个主成分。

核心思想：

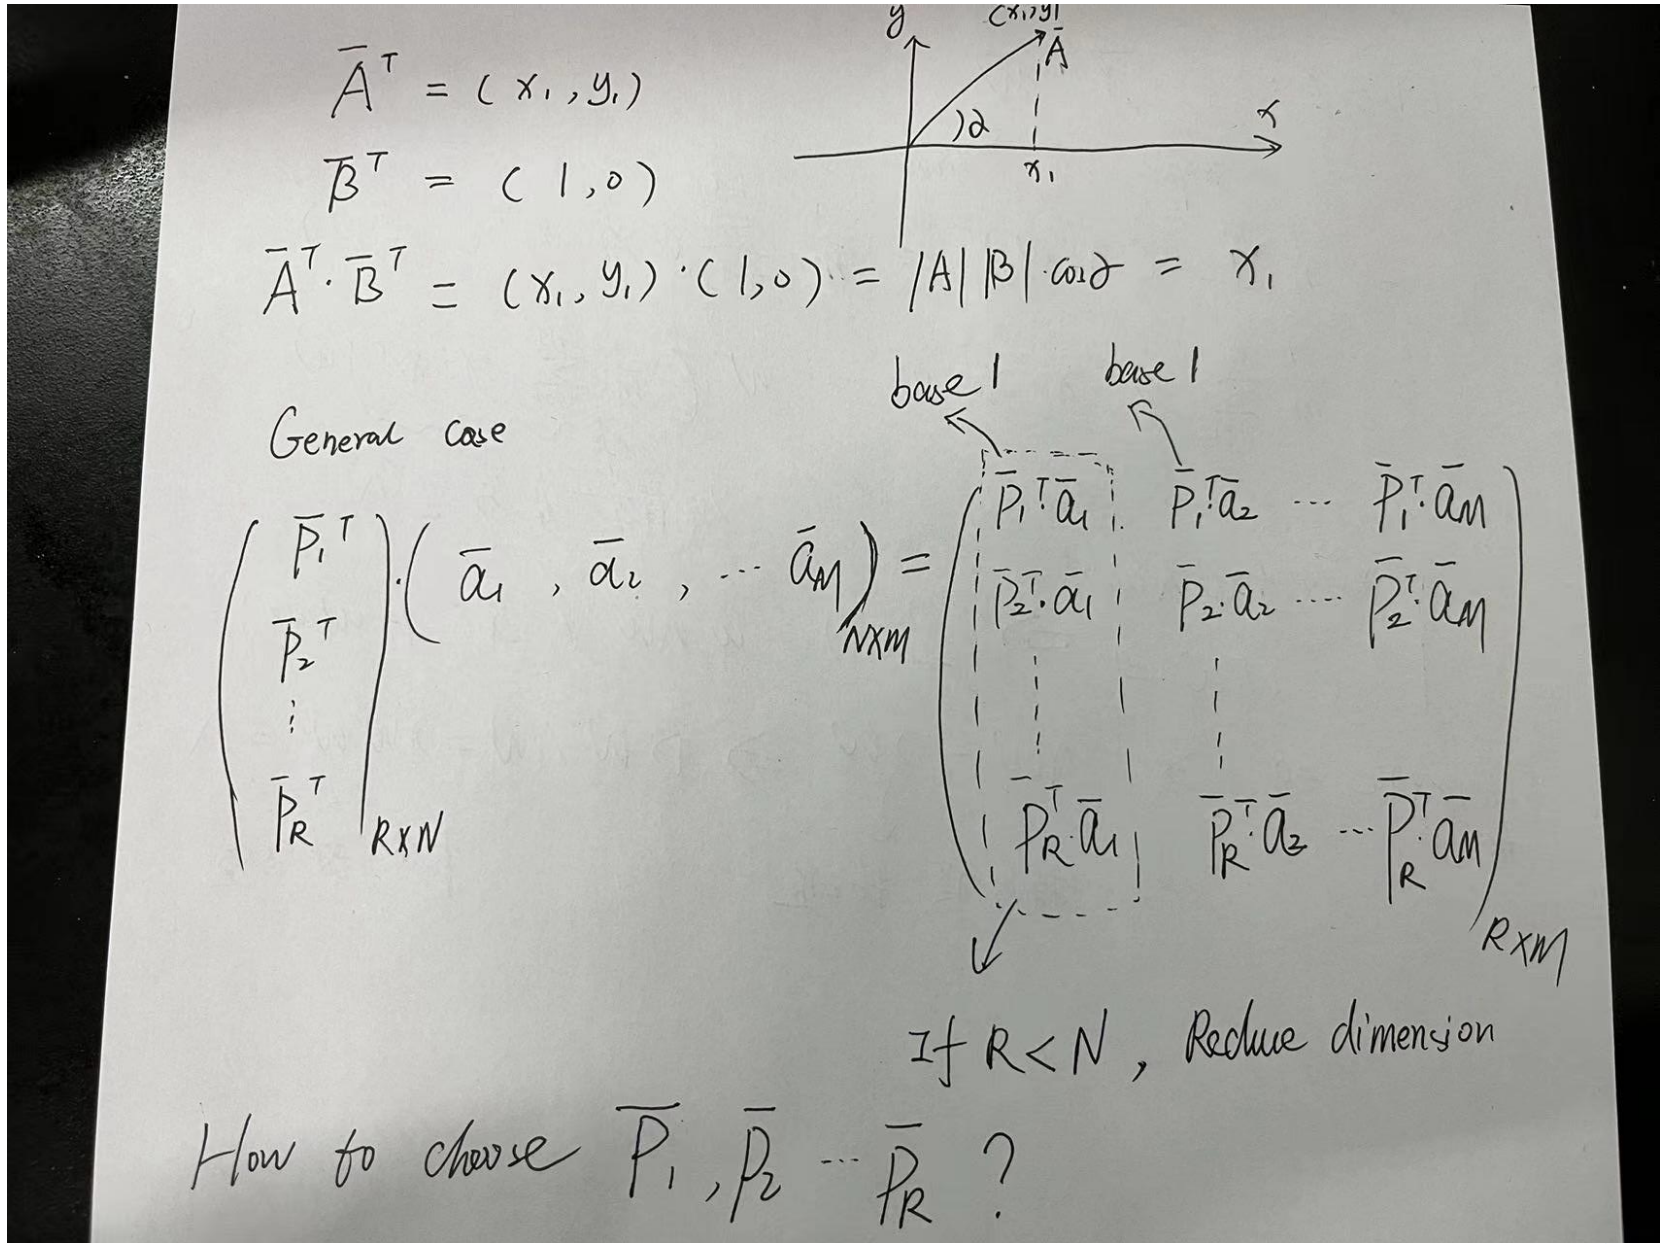
- 第一个主成分就是从数据差异性最大（**即方差最大**）的方向提取出来的，第二个主成分则来自于数据**差异性次大的方向**，并且该方向与第一个**主成分方向正交**。通过数据集的协方差矩阵及其**特征值分析**，我们就可以求得这些主成分的值。

- 一旦得到了协方差矩阵的**特征向量**，我们就可以**保留最大的N个值**。这些特征向量也给出了N个最重要特征的真实结构。我们可以通过将数据乘上这N个特征向量而将它转换到新的空间。

特征值分析

特征值分析是线性代数中的一个领域，它能够通过数据的一般格式来揭示数据的“真实”结构，即我们常说的特征向量和特征值。在等式Av = λv中，v 是特征向量，λ是特征值。特征值都是简单的标量值，因此Av = λv代表的是：如果特征向量v被某个矩阵A左乘，那么它就等于某个标量λ乘以v。幸运的是，NumPy中有寻找特征向量和特征值的模块linalg，它有eig()方法，该方法用于求解特征向量和特征值。

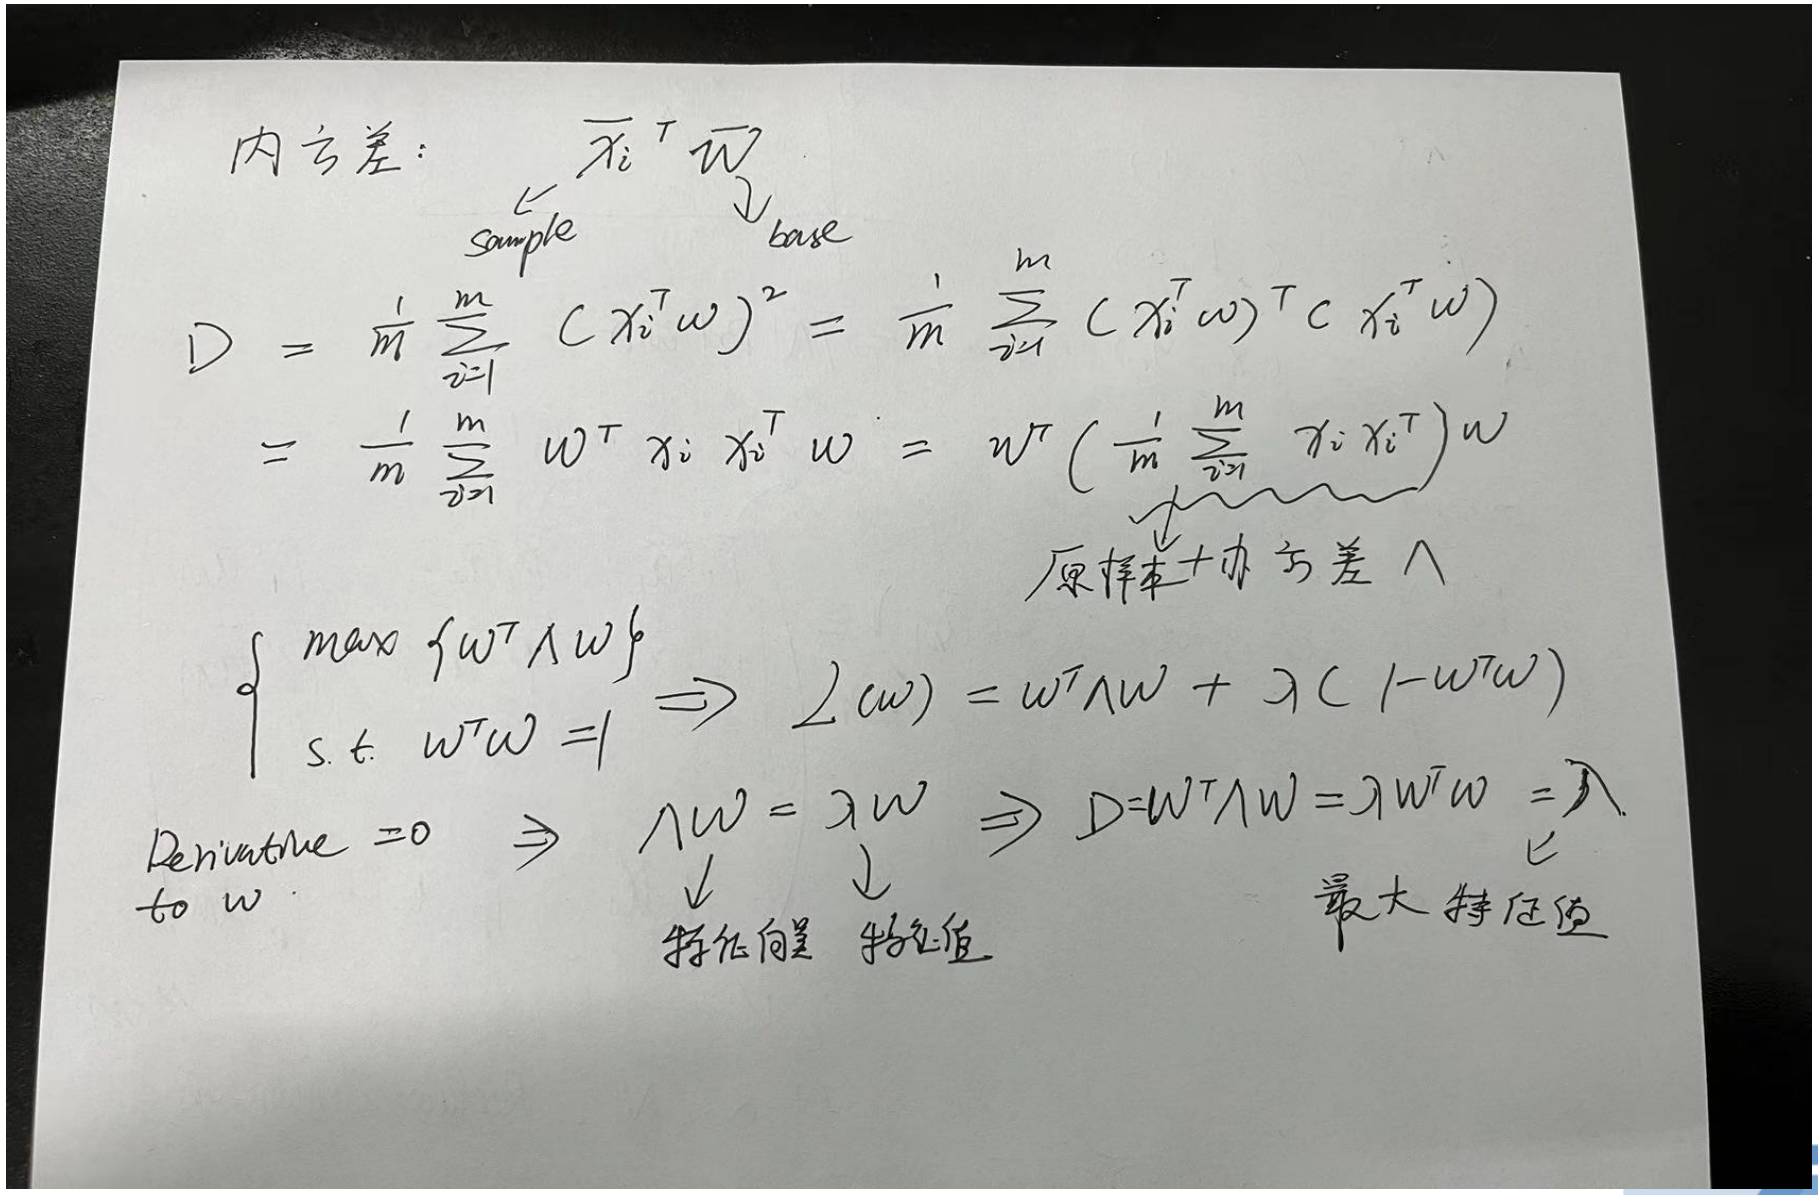
PCA：迄今为止最流行的降维方法，用于提取数据的主要特征分量。内积与基：



如何恢复信息？

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

目标：变量内方差尽可能大（投影后信息重合最小），变量间协方差为 0 （每次投影信息不重合-基正交）。



浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

1.2：代码实现PCA

主要步骤：

- 去除平均值
- 计算协方差矩阵
- 计算协方差矩阵的特征值和特征向量
- 将特征值从大到小排序
- 保留最上面的N个特征向量
- 将数据转换到上述N个特征向量构建的新空间中

数据导入

解析1：

- strip()-移除字符串头尾指定的字符（默认为空格或换行符）或字符序列；
- map(function, iterable, ...) 根据提供的函数对指定序列做映射；

```
def loadDataSet(fileName, delim='\t'):
    fr = open(fileName)
    stringArr = [line.strip().split(delim) for line in fr.readlines()]
    datArr = [list(map(float,line)) for line in stringArr]
    return mat(datArr)
```

PCA函数定义

解析1:

- 第一个参数用于进行PCA操作的数据集，第二个参数topNfeat 是一个可选参数， 即应用的N个特征。
- cov求协方差矩阵;
- argsort()函数将eigvals中的元素从小到大排列，提取index(索引) 输出;
- 索引":-(topNfeat+1):-1"表示最大的topNfeat个特征值的inx；其中第一元素表示开始inx，第二元素表示结束inx，第三元素表示步长;

```
def pca(dataMat, topNfeat=9999999):
    meanVals = mean(dataMat, axis=0)
    meanRemoved = dataMat - meanVals           #remove mean
    covMat = cov(meanRemoved, rowvar=0)
    eigVals,eigVects = linalg.eig(mat(covMat))
    eigValInd = argsort(eigVals)          #sort, sort goes smallest to largest
    eigValInd = eigValInd[:-(topNfeat+1):-1]  #cut off unwanted dimensions
    redEigVects = eigVects[:,eigValInd]     #reorganize eig vects largest to smallest
```

PCA函数定义

- 利用N个特征将原始数据转换到新空间中;
- lowDDatamat：降维之后的数据集; reconMat：从降维后的数据集中恢复的数据集

```
def pca(dataMat, topNfeat=9999999):
    meanVals = mean(dataMat, axis=0)
    meanRemoved = dataMat - meanVals           #remove mean
    covMat = cov(meanRemoved, rowvar=0)
    eigVals,eigVects = linalg.eig(mat(covMat))
    eigValInd = argsort(eigVals)          #sort, sort goes smallest to largest
    eigValInd = eigValInd[:-(topNfeat+1):-1]  #cut off unwanted dimensions
    redEigVects = eigVects[:,eigValInd]     #reorganize eig vects largest to smallest
    lowDDataMat = XXXXX          #transform data into new dimensions with PCA method
    reconMat = XXXXXX            #Recover data from LowDDataMat
    return lowDDataMat, reconMat
```

实验3-1：

（1）补充PCA函数定义中lowDDatamat和reconMat求解方式；

（2）利用PCA函数，对testSet.txt中数据做降维分析： 可视化topNfeat 分别等于1、2时，PCA降维后的输出数据；

（3）通过与原始数据对比，讨论topNfeat 分别等于1、2时的降维效果；

1.3：示例：利用 PCA 对半导体制造数据降维

半导体制造数据特点：

- 拥有590个特征；
- 数据包含很多的缺失值，以NaN（Not a Number的缩写）标识；
- 处理方式：用平均值来代替缺失值，平均值根据非NaN得到；
- nonzero用于得到数组array中非零元素的位置（数组索引）的函数

```
def replaceNanWithMean():
    datMat = loadDataSet('secom.data', ' ')
    numFeat = shape(datMat)[1]
    for i in range(numFeat):
        meanVal = mean(datMat[nonzero(~isnan(datMat[:,i].A))[0],i]) #values not NaN (a number)
        datMat[nonzero(isnan(datMat[:,i].A))[0],i] = meanVal  #set NaN values to mean
    return datMat
```

实验3-2：
利用PCA，对secom.data数据降维，（1）讨论topNfeat 取值对降维数据的影响；（2）找到降维后恢复的数据与原始数据相对误差小于9%的最小topNfeat值；

相对误差定义如下：
Re_err=linalg.norm(dataMat-reconMat) / linalg.norm(dataMat)