

Topic 3 降维技术
Part 2：线性判别分析（LDA）

魏准
浙江大学，信息与电子工程学院
2026

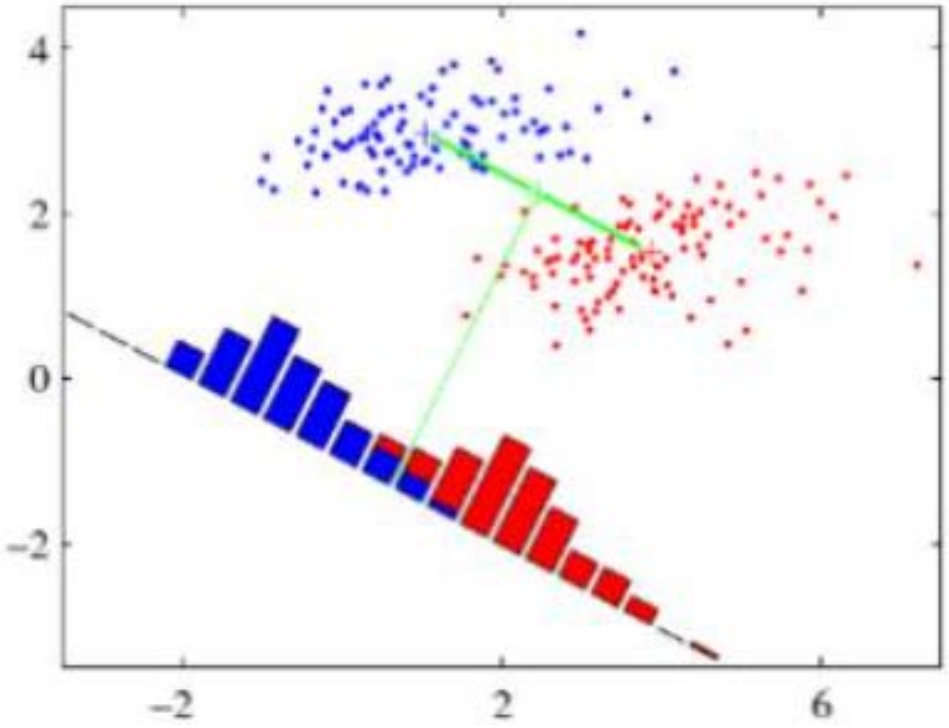
总体内容

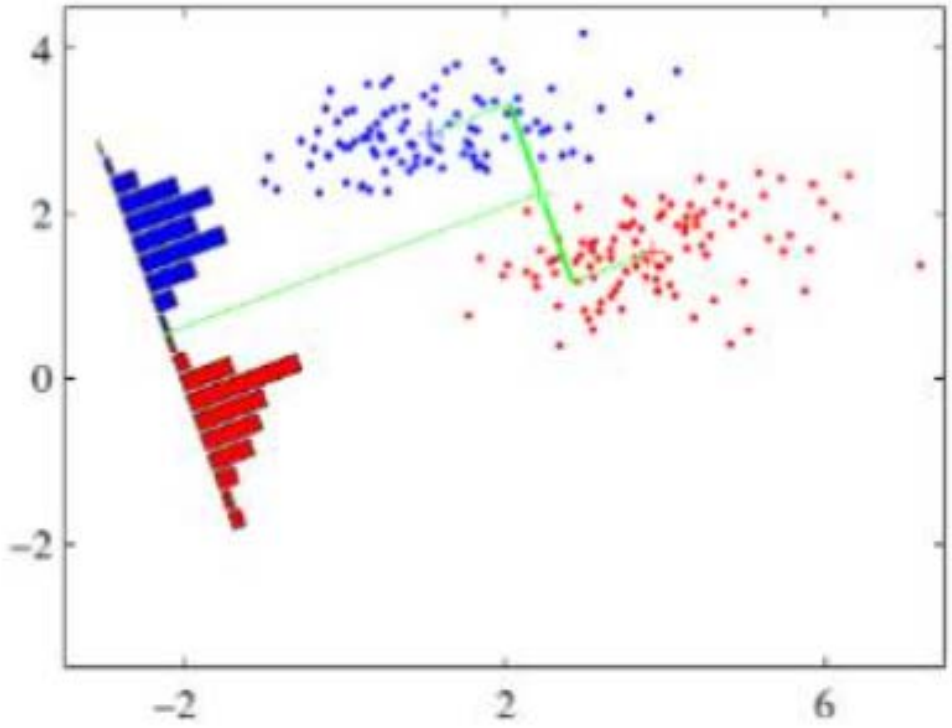
主要知识点

- 线性判别分析(LDA)；
  - ◆ LDA解析-二维数据
  - ◆ LDA解析-多分类问题
  - ◆ LDA VS PCA
- 实验3-3；
- LDA代码实现解析；

1.1：线性判别分析(Linear Discriminant Analysis，LDA)

LDA-“投影后**类内方差最小，类间方差最大**”： 将数据在低维度上进行投影，投影后希望每一种类别数据的投影点尽可能的接近，而不同类别的数据的类别中心之间的距离尽可能的大。**分类+降维**

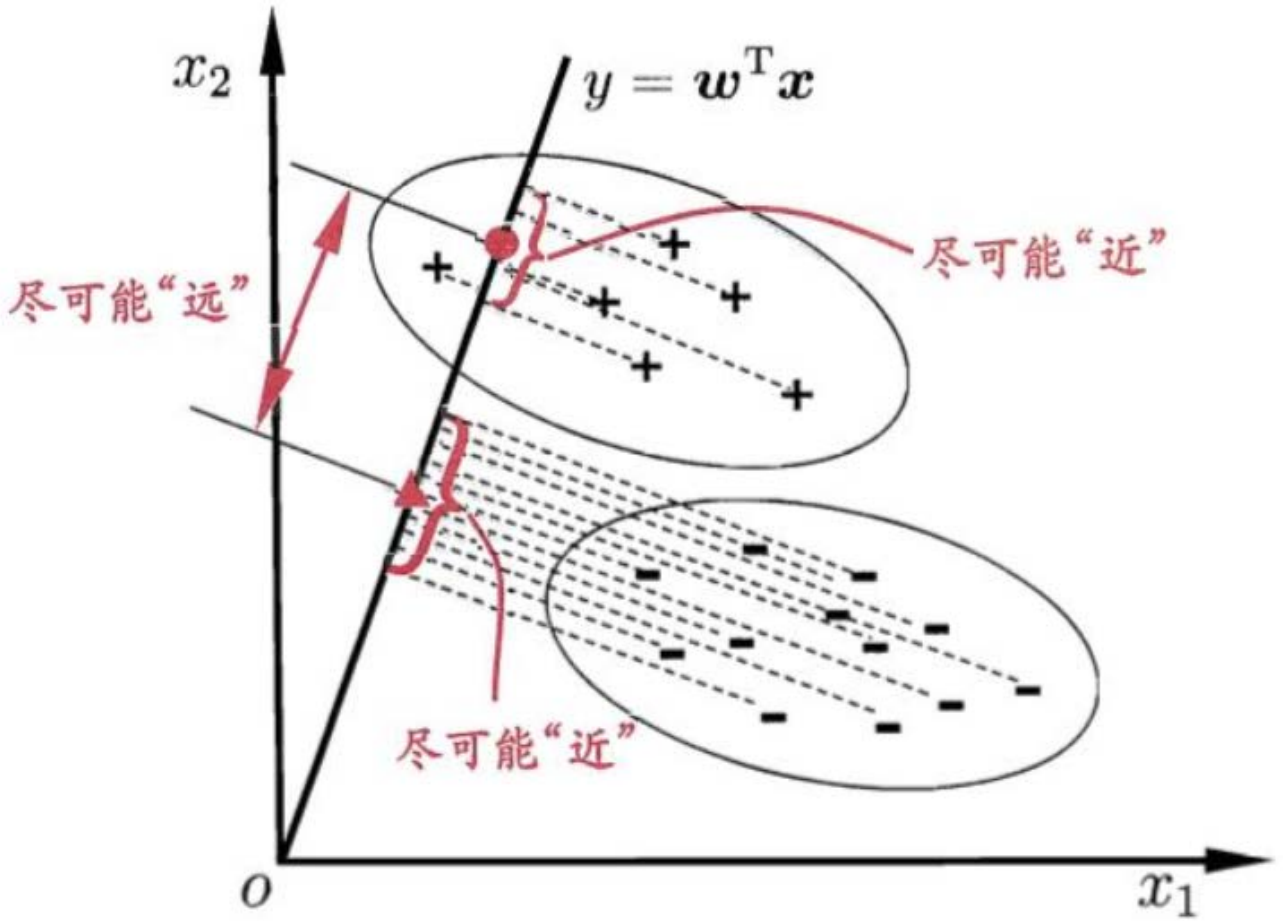




1.1.1 LDA解析-二维数据

降维：假设两类二维数据： “+”和“-”， 希望投影到一维的一条直线；

目标：让同类数据的投影点尽可能接近， 不同数据中心之间的距离尽可能大。

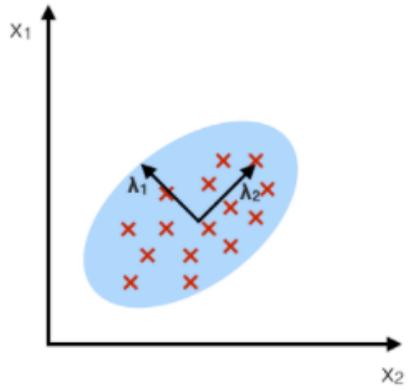


1.1.3 LDA VS PCA

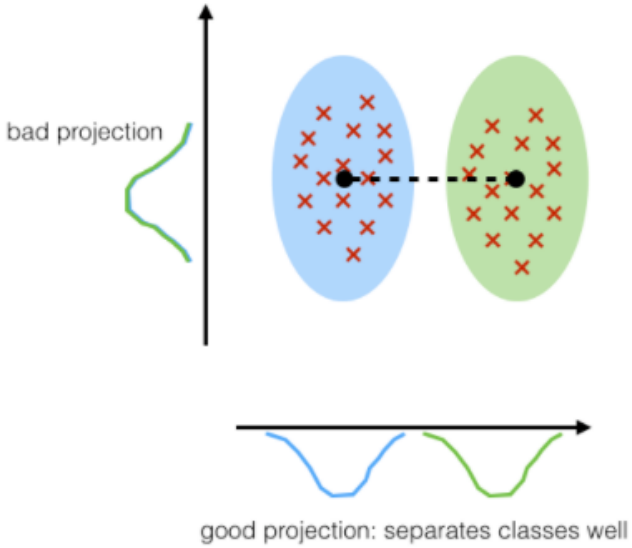
相同点：

- 两者均可以对数据进行**降维**。
- 两者在降维时均使用了**矩阵特征分解**的思想。

PCA:
component axes that maximize the variance

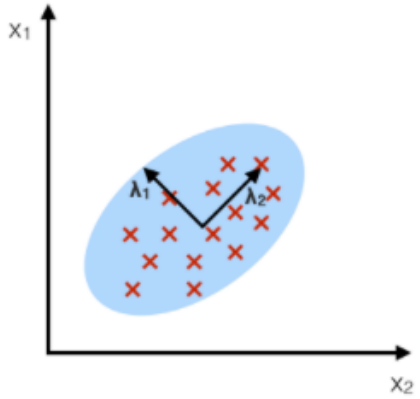


LDA:
maximizing the component axes for class-separation

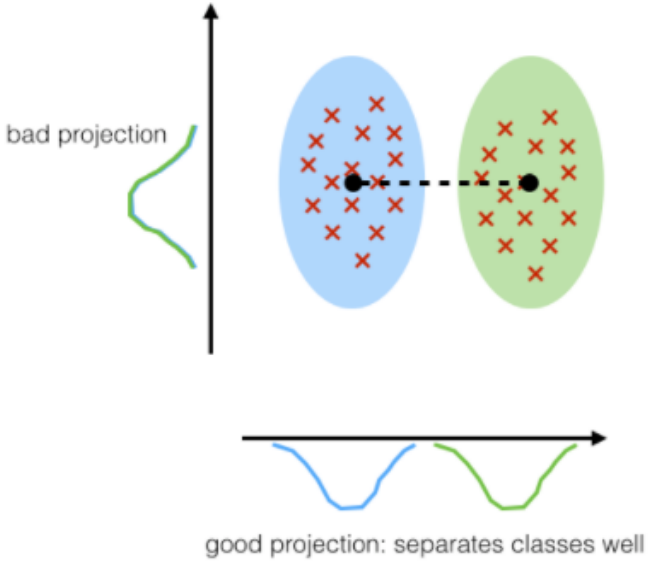


- **PCA**是为了让映射后的样本具有最大的发散性；而**LDA**是为了让映射后的样本有最好的分类性能。所以说**PCA**是一种无监督的降维方法，而**LDA**是一种有监督的降维方法。
- **LDA**降维最多降到类别数N-1的维数，而**PCA**没有这个限制。
- **LDA**除了可以用于降维，还可以用于分类。

PCA:
component axes that maximize the variance



LDA:
maximizing the component axes for class-separation



假设最佳向量设为ω，样本x在ω的投影为：

$$y = \omega^{T} x$$

如何求解ω?

二分类

给定数据集 $D = \{(x_i, y_i)\}_{i=1}^{m}$ ，$y_i \in \{0,1\}$ ，令 N_i 、 X_i 、 μ_i 、 Σ_i 分别表示第 $i \in \{0,1\}$ 类示例的样本个数、样本集合、均值向量、协方差矩阵。

μ_i 的表达式： $\mu_i = \frac{1}{N_i} \sum_{x \in X_i} x \quad (i = 0,1)$

Σ_i 的表达式： $\Sigma_i = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^{\top} \quad (i = 0,1)$

LDA目标：让同类数据的投影点尽可能接近， 不同数据中心之间的距离尽可能大。

用μ_0, μ_1分别表示两个类别的中心点（均值）， 则希望

$$J(w) = \frac{||w^\top \mu_0 - w^\top \mu_1||_2^2}{\tilde{S}_0^{\,2} + \tilde{S}_1^{\,2}}$$

不同数据中心之间的距离尽可能大

同类样本间的方差：越小越好

最大化，其中散度值（scatter）定义为：

$$\tilde{S}^2 = \sum_{x \in X_i} (w^\top x - \tilde{\mu}_i)^2$$

$\tilde{\mu}_i$表示样本的两个中心在直线ω上面的投影$\omega^{\mathrm{T}}\mu_{\mathrm{i}}$。

目标：找到使J(ω)最大的ω。

J(ω)分母变换：

散度值公式可以表示为：

$$\tilde{S}^2 = \sum_{x \in X_i} (w^\top x - \tilde{u}_i)^2 = \sum_{x \in X_i} w^\top (x - \mu_i)(x - \mu_i)^\top w$$

定义散度矩阵（scatter matrices）

$$\Sigma_i = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^\top$$

类内散度矩阵定义为：

$$S_w = \Sigma_0 + \Sigma_1$$

$$J(w) = \frac{||w^\top \mu_0 - w^\top \mu_1||_2^2}{\tilde{S}_0^{\,2} + \tilde{S}_1^{\,2}}$$

J(ω)分子变换：

$$||w^\top \mu_0 - w^\top \mu_1||_2^2 = w^\top (\mu_0 - \mu_1)(\mu_0 - \mu_1)^\top w$$

定义**类间**散度矩阵”（between-class scatter matrix）

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^\top$$

$$J(w) = \frac{||w^\top \mu_0 - w^\top \mu_1||_2^2}{\tilde{S_0}^2 + \tilde{S_1}^2}$$

J(ω)可表示为：

$$J(w) = \frac{w^\top S_b w}{w^\top S_w w}$$

“广义瑞利商”(generalized Rayleigh quotient)。

J(ω)分子分母都是ω的二次项，因此J(ω) 解与ω的长度无关，只与其方向相关。 J(ω) 最大化问题等效为

$$\min_{w} -w^{\top} S_b w$$

$$s.t. \quad w^{\top} S_w w = 1$$

$$J(w) = \frac{w^{\top} S_b w}{w^{\top} S_w w}$$

由拉格朗日乘子法，上式等价于：

$$c(w) = -w^{\top} S_b w + \lambda(w^{\top} S_w w - 1)$$

$$\Rightarrow \frac{dc}{dw} = -2S_b w + 2\lambda S_w w = 0$$

$$\Rightarrow \quad S_b w = \lambda S_w w$$

实数

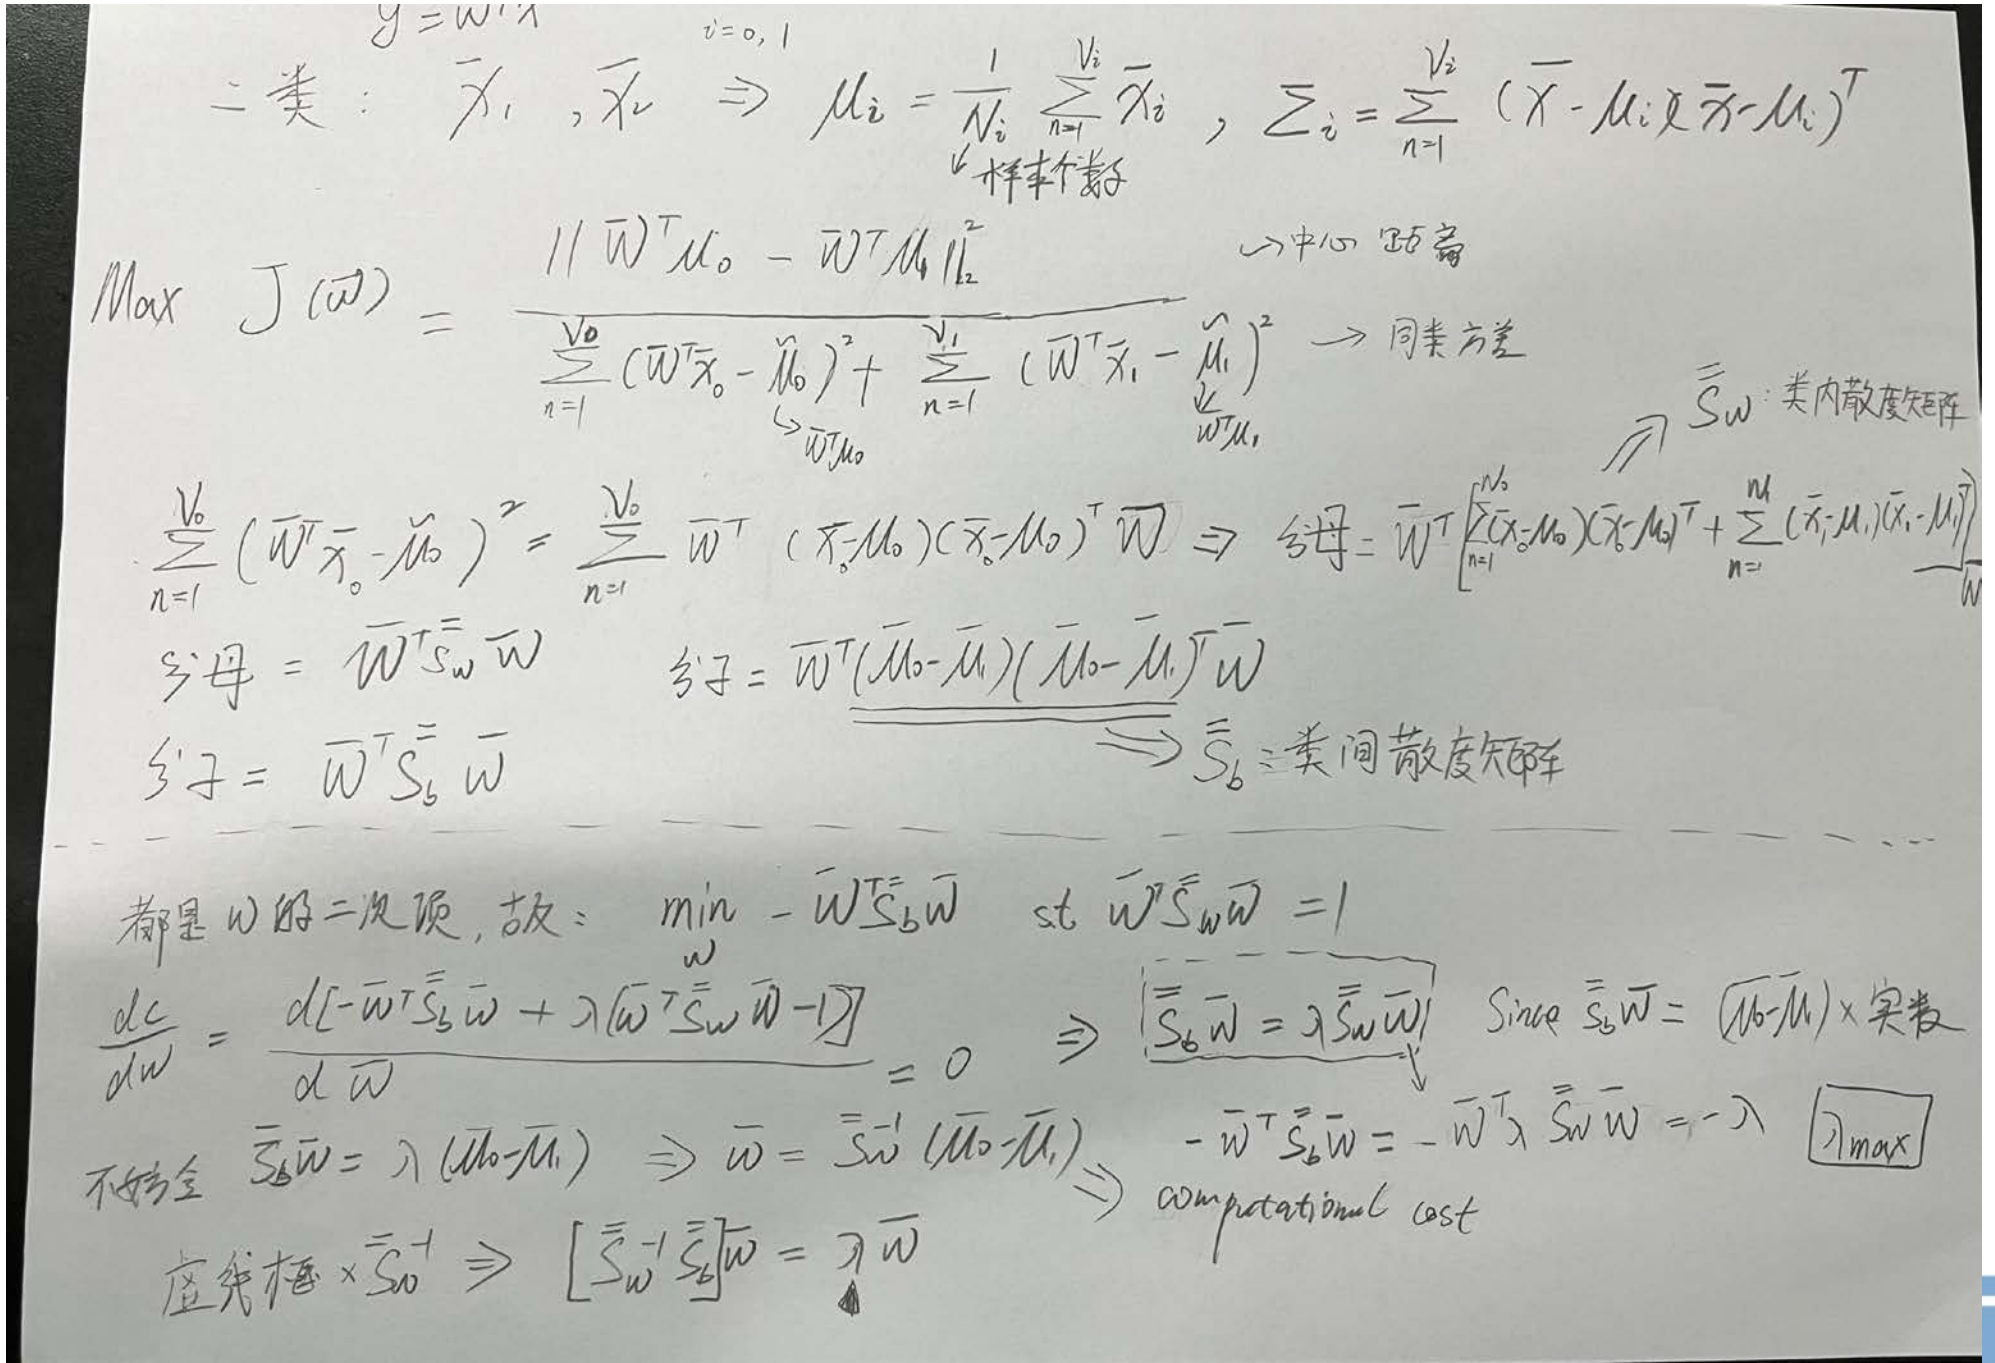
$$S_{\mathrm{b}}\omega = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^T \omega$$

λ为拉格朗日乘子。由于$S_{\mathrm{b}}\omega$的方向恒为$\mu_0 - \mu_1$，不妨令

$$S_b w = \lambda(\mu_0 - \mu_1) \Rightarrow w = S_w^{-1}(\mu_0 - \mu_1)$$

代入上式

LDA目标：让同类数据的投影点尽可能接近， 不同数据中心之间的距离尽可能大。



浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

1.1.2 LDA解析-多分类问题

假设存在N个类，且第i类示例数(sample data)为$\mathbf{m}_i$

二分类

$$S_b w = \lambda S_w w$$

$$S_b = (\mu_0 - \mu_1)(\mu_0 - \mu_1)^\top$$

$$S_w = \Sigma_0 + \Sigma_1$$

$$\Sigma_i = \sum_{x \in X_i} (x - \mu_i)(x - \mu_i)^\top$$

多分类

$$\mathbf{S}_b \mathbf{W} = \lambda \mathbf{S}_w \mathbf{W}$$

$$S_\mathrm{b} = \sum_{i=1}^{N} m_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^\mathrm{T}$$

第i类示例数

所有示例的均值向量

$$\mathbf{S}_w = \sum_{i=1}^{N} \mathbf{S}_{w_i}$$

$$\mathbf{S}_{w_i} = \sum_{\boldsymbol{x} \in X_i} (\boldsymbol{x} - \boldsymbol{\mu}_i)(\boldsymbol{x} - \boldsymbol{\mu}_i)^\mathrm{T}$$

- W的解为$S_\omega^{-1} S_\mathrm{b}$的d个**最大非零特征值**所对应的特征向量组成的矩阵；
- W是一个利用了样本的类别得到的投影矩阵，因此它的降维到的维度d最大值为N-1（S_b**最**的秩**最大为N-1**）。

实验3-3：

利用np.random.random函数，生成两个类别的随机数据，样本大小为30*2（行表示样本数，2表示特征数），其中随机数A的取值范围为10-13，随机数据B的取值范围为15-18；通过LDA对生成的随机数据进行降维，并在同一张图内可视化降维直线和原始数据。

具体步骤：

- **Step 1**:定义函数-计算类内离散度矩阵Sw的单元;
- **Step 2**:定义函数-类间离散度矩阵Sb;
- **Step 3**:定义函数- LDA求解W
  - ✓ W的解为$S_\omega^{-1}S_\mathrm{b}$的d个**最大非零特征值**所对应的特征向量;
- **Step 4**:编写测试函数- 产生随机数、利用LDA函数求出直线W，并在同一张图上可视化直线W和原始数据;

$$\mathbf{S}_b\mathbf{W} = \lambda\mathbf{S}_w\mathbf{W}$$

$$S_\mathrm{b} = \sum_{i=1}^{N} m_i(\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^\mathrm{T}$$

$$\mathbf{S}_w = \sum_{i=1}^{N} \mathbf{S}_{w_i}$$

$$\mathbf{S}_{w_i} = \sum_{\boldsymbol{x}\in X_i} (\boldsymbol{x} - \boldsymbol{\mu}_i)(\boldsymbol{x} - \boldsymbol{\mu}_i)^\mathrm{T}$$

1.2 LDA代码实现解析；

Step 1:计算均值

```
def mean_val(data_np):  #输入是numpy的format，行表示样本数，列表示特征
    return np.mean(data_np, axis=0)
```

Step 2:计算类内离散度矩阵Sw的单元

```
def compute_Sw_0(xi):
    n = xi.shape[0]
    ui = mean_val(xi)
    Sw_0 = 0
    for i in range(0, n):
        Sw_0 = Sw_0 + np.outer((xi[i, :] - ui), (xi[i, :] - ui))
    return Sw_0
```

Step 3:类间离散度矩阵Sb

```
def compute_Sb(x1, x2):
      XXXXXX
```

Step 4:LDA求解

```
def LDA(x1, x2):
      XXXXXX
```

Step 5:测试

```
import matplotlib.pyplot as plt
from LAD_Zhun import *
XXXXXX
```